

**VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY**



NGUYEN PHUONG NAM

**LONGITUDINAL LEARNING WITH TENSOR FUSION
FOR PREDICTING PROGRESSION OF ALZHEIMER'S
DISEASE**

BACHELOR THESIS

Major: Artificial Intelligence

HA NOI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

NGUYỄN PHƯƠNG NAM

HỌC DẠC THEO THỜI GIAN VỚI HỢP NHẤT TENSOR
ĐỂ DỰ BÁO TIẾN TRIỂN BỆNH ALZHEIMER

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN

Ngành: Trí tuệ nhân tạo

Cán bộ hướng dẫn: GS. Nguyễn Linh Trung

Cán bộ đồng hướng dẫn: TS. Nguyễn Thành Trung

HÀ NỘI - 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

NGUYEN PHUONG NAM

LONGITUDINAL LEARNING WITH TENSOR FUSION
FOR PREDICTING PROGRESSION OF ALZHEIMER'S
DISEASE

BACHELOR THESIS

Major: Artificial Intelligence

Supervisor: Prof. Nguyen Linh Trung

Co-Supervisor: Dr. Nguyen Thanh Trung

HA NOI - 2026

TÓM TẮT

Khóa luận *Longitudinal Learning with Tensor Fusion for Predicting Progression of Alzheimer's Disease* nghiên cứu dự báo tiến triển MCI dưới dạng bài toán sống còn độc đa phương thức. Từ khung CNN-T-LSTM của Aghajanian và cộng sự, nghiên cứu phát triển lần lượt các baseline MRI, ghép nối đa phương thức, tương tác từng cặp và kiến trúc hợp nhất gọn hơn; phân rã tensor được đưa vào sau khi đánh giá chi phí của outer-product.

Cohort ADNI đã đóng băng gồm 359 người, với 106 biến cố. Ba MRI được chọn trong cửa sổ đủ điều kiện 18 tháng. MRI thứ ba xác định mốc tham chiếu dự báo; biến cố được xác định sau landmark đủ điều kiện bằng ngưỡng MMSE/CDR. Dữ liệu clinical được ghép theo ngày gần nhất trong cửa sổ ± 90 ngày quanh MRI, nên tính sẵn có của toàn bộ đầu vào tại mốc dự báo cần được kiểm tra riêng khi triển khai tiến cứu.

Ba tương tác MRI-Radiomics (MR), MRI-Clinical (MC) và Radiomics-Clinical (RC) ban đầu dùng outer-product và định tuyến residual có cổng động. CP sau đó tham số hóa tensor *trọng số* của phép song tuyến, giữ nguyên MLP phía sau. Lỗi tương tác ba cặp giảm từ 229,696 xuống 3,712 tham số; validation C-index trung bình ba seed thay đổi từ 0.8344 xuống 0.8278. Ablation dẫn đến kiến trúc RC-Free Pairwise Fusion: vẫn giữ cả ba modality nhưng chỉ duy trì MR/MC. Bốn route có sigmoid gate phụ thuộc đầu vào và scale toàn cục học được, trước T-LSTM, attention theo thời gian và Cox head.

Trên benchmark chuẩn hóa, RC-Free Pairwise Fusion đạt validation C-index 0.8347 ± 0.0237 (độ lệch chuẩn mẫu qua ba seed). Kết quả ủng hộ một kiến trúc gọn có hiệu năng cạnh tranh, chưa chứng minh ưu thế thống kê. Baseline sống còn cổ điển vẫn mạnh theo quy trình lựa chọn và quy ước concordance riêng. Kiến trúc được chọn bằng validation; việc truy cập test trong lịch sử được ghi nhận như một giới hạn. Đánh giá cuối cùng theo protocol held-out chính thức chưa được thực hiện.

Từ khóa: Alzheimer, MCI, MRI đọc, radiomics, hợp nhất tensor, phân rã CP, gated residual, T-LSTM, phân tích sống còn.

ABSTRACT

This thesis, *Longitudinal Learning with Tensor Fusion for Predicting Progression of Alzheimer’s Disease*, studies longitudinal multimodal survival prediction of MCI progression. Starting from the CNN–T-LSTM framework of Aghajanian et al., the research develops MRI baselines, multimodal concatenation, explicit pairwise interaction, and a compact fusion architecture rather than assuming tensor factorization from the outset.

The frozen ADNI cohort contains 359 participants, including 106 events. Three MRI visits are selected within an 18-month eligibility window. The third MRI defines the model’s prediction reference time; event ascertainment begins after the eligibility landmark. The operational endpoint uses MMSE/CDR thresholds. Clinical features follow a retrospective nearest-date alignment within ± 90 days of each MRI, which limits claims about prospective availability at the reference time.

MRI–Radiomics (MR), MRI–Clinical (MC), and Radiomics–Clinical (RC) interactions were first modeled through outer products and dynamic gated residual routing. CP then factorizes the bilinear *weight tensor*, while the subsequent pair-specific MLP remains unchanged. The full three-pair interaction core falls from 229,696 to 3,712 parameters; three-seed mean validation C-index changes from 0.8344 to 0.8278. Ablation motivates the selected RC-Free Pairwise Fusion architecture, retaining every modality and only the MR/MC interactions. Its four routes use input-dependent sigmoid gates and learnable global route scales, followed by T-LSTM, temporal attention, and a Cox risk head.

In the standardized benchmark, RC-Free Pairwise Fusion achieves validation C-index 0.8347 ± 0.0237 (sample SD over three seeds). The result supports a compact competitive architecture, without establishing statistical superiority. Classical survival baselines remain strong under their own selection and concordance conventions. Architecture selection uses validation evidence; historical test access is disclosed as a limitation. Formal held-out final evaluation has not yet been performed.

Keywords: Alzheimer’s disease, MCI, longitudinal MRI, radiomics, tensor fusion, CP factorization, gated residual routing, T-LSTM, survival analysis.

LỜI CẢM ƠN

Em xin bày tỏ lòng biết ơn sâu sắc tới GS. TS. Nguyễn Linh Trung và Thượng tá, TS. Nguyễn Thành Trung, Phó Chủ nhiệm Khoa Trang bị, Bệnh viện 108. Sự định hướng tận tình, những góp ý quý báu và các trao đổi nghiêm túc của các thầy đã giúp em từng bước xác định hướng đi, hiểu rõ hơn yêu cầu khoa học của đề tài và có thêm niềm tin để kiên trì hoàn thành khóa luận.

Em xin chân thành cảm ơn Cử nhân Nguyễn Phương Trang đã luôn sẵn lòng hỗ trợ, hướng dẫn và trao đổi với em trong suốt quá trình thực hiện đề tài. Những góp ý cụ thể cùng sự đồng hành ấy đã giúp em tháo gỡ nhiều vướng mắc và tiếp thêm động lực mỗi khi công việc nghiên cứu trở nên khó khăn.

Em xin trân trọng cảm ơn ông Sepehr Aghajanian, tác giả của bài báo nền tảng được tham khảo trong khóa luận, đã dành thời gian hồi đáp email và giải đáp những câu hỏi của em. Sự cởi mở và tận tâm ấy giúp em hiểu sâu hơn công trình nghiên cứu mà mình kế thừa, đồng thời khiến em thêm trân trọng tinh thần chia sẻ trong cộng đồng khoa học.

Em biết ơn tập thể Lab Avitech đã tạo điều kiện sử dụng tài nguyên máy chủ phục vụ việc huấn luyện mô hình và thực hiện các thí nghiệm. Sự hỗ trợ thiết thực về hạ tầng tính toán đã giúp em có thể theo đuổi quá trình thực nghiệm và hoàn thành nghiên cứu.

Em xin cảm ơn các thầy cô Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội đã trao cho em nền tảng kiến thức quý báu. Em cũng xin ghi nhận đóng góp của các nhà nghiên cứu, cơ sở lâm sàng, nhà tài trợ và người tham gia Alzheimer's Disease Neuroimaging Initiative (ADNI), những người đã cùng xây dựng và duy trì nguồn dữ liệu có giá trị cho nghiên cứu này.

Sau cùng, em xin gửi lời biết ơn chân thành tới gia đình và những người thân yêu vì tình thương, niềm tin và sự động viên bền bỉ. Sự ủng hộ ấy là điểm tựa giúp em vững lòng trước những thử thách và đi đến những dòng cuối cùng của khóa luận.

LỜI CAM ĐOAN

Tôi cam đoan nội dung trong khóa luận này là kết quả nghiên cứu và triển khai của cá nhân tôi dưới sự hướng dẫn của các giảng viên. Các ý tưởng, công thức và kết quả từ công trình khác được trích dẫn rõ ràng trong phần tài liệu tham khảo. Dữ liệu ADNI được sử dụng theo các quy định truy cập và sử dụng dữ liệu tương ứng.

Các số liệu thực nghiệm được đối chiếu với báo cáo có cấu hình, seed, phân chia dữ liệu và provenance được lưu vết. Việc lựa chọn kiến trúc trong khóa luận dựa trên validation; các giới hạn về endpoint, thời gian đầu vào và lịch sử truy cập test được trình bày rõ. Đánh giá held-out cuối cùng theo protocol chính thức chưa được thực hiện.

Hà Nội, năm 2026

Nguyễn Phương Nam

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nội dung
AD	Alzheimer's Disease – bệnh Alzheimer
ADNI	Alzheimer's Disease Neuroimaging Initiative
CDR	Clinical Dementia Rating
C-index	Concordance index
CN	Cognitively Normal
CP	CANDECOMP/PARAFAC, còn gọi là Canonical Polyadic decomposition
CNN	Convolutional Neural Network
GLCM	Gray-Level Co-occurrence Matrix
GLDM	Gray-Level Dependence Matrix
GLRLM	Gray-Level Run Length Matrix
GLSZM	Gray-Level Size Zone Matrix
LN	Layer Normalization
MCI	Mild Cognitive Impairment – suy giảm nhận thức nhẹ
MLP	Multi-Layer Perceptron
MMSE	Mini-Mental State Examination
MRI	Magnetic Resonance Imaging
NGTDM	Neighbouring Gray Tone Difference Matrix
PCA	Principal Component Analysis
PH	Proportional Hazards
RID	Research Identifier trong ADNI
T-LSTM	Time-Aware Long Short-Term Memory

MỤC LỤC

TÓM TẮT	iii
ABSTRACT	iv
LỜI CẢM ƠN	v
LỜI CAM ĐOAN	vi
DANH MỤC TỪ VIẾT TẮT	vii
Chương 1 Giới thiệu	1
1.1 Động lực nghiên cứu	1
1.2 Phát biểu bài toán	2
1.3 Câu hỏi nghiên cứu	3
1.4 Mục tiêu nghiên cứu	4
1.5 Đóng góp của khóa luận	5
1.6 Cấu trúc khóa luận	5
Chương 2 Cơ sở lý thuyết và nghiên cứu liên quan	6
2.1 MCI và tiến triển Alzheimer	6
2.2 Mô hình dọc và phân tích sống còn	6
2.2.1 Sự kiện, kiểm duyệt và mô hình Cox	6
2.2.2 T-LSTM và attention theo visit	7
2.3 Thông tin đa phương thức	8
2.3.1 MRI cấu trúc và biểu diễn học sâu	8
2.3.2 Vision Transformer và biểu diễn ảnh 3D	8
2.3.3 Radiomics và giảm chiều	9
2.3.4 Biến lâm sàng và observedness masks	9
2.4 Các chiến lược hợp nhất đa phương thức	9
2.5 Tương tác song tuyến và phân rã tensor	10
2.6 Gated residual fusion	11

2.7	Các nghiên cứu liên quan	12
2.8	Khoảng trống nghiên cứu	13
Chương 3	Phương pháp	14
3.1	Thiết kế nghiên cứu và xây dựng dữ liệu	14
3.1.1	Tiêu chí chọn mẫu và ba visits	14
3.1.2	Event, censoring và mốc tính thời gian	15
3.1.3	Phân chia và bảo vệ quá trình học	16
3.2	Tiền xử lý và biểu diễn từng modality	16
3.2.1	MRI và shared encoder	16
3.2.2	Radiomics	18
3.2.3	Clinical và observedness masks	18
3.2.4	Thư viện và triển khai	19
3.3	Quá trình phát triển kiến trúc	19
3.4	Multimodal Concatenation baseline	22
3.5	Dynamic Pairwise Fusion	22
3.6	CP-factorized pairwise interaction	22
3.7	Dynamic gated residual routing	25
3.8	RC-Free Pairwise Fusion	25
3.9	Tổng quan pipeline cuối	27
3.10	Mô hình thời gian và temporal attention	29
3.11	Cox objective, huấn luyện và lựa chọn mô hình	30
Chương 4	Thực nghiệm, kết quả và phân tích	32
4.1	Giao thức thực nghiệm	32
4.2	Baseline cổ điển và dữ liệu bảng	33
4.3	Baseline MRI một thời điểm	34
4.4	MRI dọc theo thời gian	35
4.5	Multimodal Concatenation	35
4.6	Dynamic Pairwise Fusion	36
4.7	Paper CNN-T-LSTM Adaptation	37
4.8	CP-Factorized Pairwise Fusion	38
4.9	Ablation của các thành phần fusion	38
4.10	RC-Free Pairwise Fusion qua nhiều seed	40
4.11	Benchmark validation chuẩn hóa	40
4.12	Hiệu quả về số tham số	41

4.13	Trả lời câu hỏi nghiên cứu và trạng thái test	44
Chương 5	Thảo luận, kết luận và hướng phát triển	45
5.1	Thảo luận	45
5.2	Giới hạn	46
5.3	Kết luận	47
5.4	Hướng phát triển	47
TÀI LIỆU THAM KHẢO		48

DANH MỤC HÌNH VẼ

Hình 1.1	Bài toán dự báo tiến triển MCI theo thời gian	2
Hình 2.1	Phân loại các chiến lược hợp nhất đa phương thức	10
Hình 3.1	Quy trình xây dựng cohort dọc	15
Hình 3.2	Ba nhánh xử lý modality	17
Hình 3.3	Tiến hóa của framework	20
Hình 3.4	Full pairwise graph và sáu routes	23
Hình 3.5	Tensor trọng số 3D và CP-factorized bilinear	24
Hình 3.6	Giải phẫu một gated residual route	26
Hình 3.7	Residual routing của RC-Free Pairwise Fusion	27
Hình 3.8	Kiến trúc tổng thể của framework cuối	28
Hình 3.9	T-LSTM và temporal attention	30
Hình 4.1	Milestone validation theo các giao thức phát triển	37
Hình 4.2	Ablation delta so với full CP	39
Hình 4.3	Benchmark validation chuẩn hóa trên ba seed	41
Hình 4.4	Tham số outer-product và CP theo từng phạm vi	42
Hình 5.1	MRI làm trung tâm của topology RC-Free	46

DANH MỤC BẢNG

Bảng 1.1	Câu hỏi nghiên cứu định hướng các thực nghiệm.	4
Bảng 2.1	Các nghiên cứu liên quan và vị trí của khóa luận. Hai công trình cuối có tác vụ khác với survival ranking, nhưng cung cấp góc nhìn về cấu trúc tensor và fusion thích nghi.	12
Bảng 3.1	Shape của shared MRI encoder	18
Bảng 3.2	Giao diện shape theo giai đoạn phát triển	21
Bảng 3.3	Shape Paper CNN-T-LSTM và CrossFormer3D	21
Bảng 3.4	Cấu hình CP của full reference và kiến trúc cuối.	24
Bảng 3.5	Shape theo từng bước của kiến trúc RC-Free	29
Bảng 4.1	Các giao thức phải phân biệt khi đọc tiến trình thực nghiệm. . .	33
Bảng 4.2	Validation của các representation dữ liệu bảng. Dòng in đậm đạt C-index cao nhất ở cả Cox và RSF. Dấu “-” nghĩa là RSF không được chạy cho representation đó.	34
Bảng 4.3	Milestone MRI-only trên seed 20260727; dòng in đậm có C-index cao nhất. Dòng attention có provenance giới hạn và không thuộc benchmark ba seed.	35
Bảng 4.4	Ablation validation ở seed 20260727; Δ được tính so với full CP. Dòng in đậm có C-index cao nhất.	39
Bảng 4.5	C-index validation chuẩn hóa: mean $\pm$ sample SD ($n = 3$). Hai dòng in đậm đồng hạng theo mean. Seed 27/28/29 là 20260727/20260728/20260729.	40
Bảng 4.6	Số tham số phép biến đổi song tuyến đầu tiên, gồm bias. CP ranks MR/MC/RC là 8/8/4.	42
Bảng 4.7	Kết luận cho các câu hỏi nghiên cứu, giới hạn ở evidence validation hiện có.	44

Chương 1

Giới thiệu

1.1 Động lực nghiên cứu

Khóa luận dùng nghiên cứu *Longitudinal structural MRI-based deep learning and radiomics features for predicting Alzheimer's disease progression* của Aghajanian và cộng sự [1] làm công trình tham chiếu ban đầu để phát triển và so sánh phương pháp. Nghiên cứu đó phân tích ảnh chụp cộng hưởng từ cấu trúc T1 (MRI T1) ở nhiều thời điểm, dùng mạng nơ-ron CNN để rút đặc trưng từ ảnh, T-LSTM để xem sự thay đổi qua các lần chụp, cơ chế attention để mô hình tập trung vào thông tin quan trọng và mô hình sống còn để xếp hạng nguy cơ biến cố theo thời gian. Kết quả bài báo cho thấy việc thêm radiomics chưa giúp mô hình tốt lên một cách ổn định; vì vậy, khóa luận kiểm tra xem ảnh MRI, các đặc trưng số mô tả ảnh và thông tin lâm sàng nên được kết hợp với nhau như thế nào.

Bệnh Alzheimer (Alzheimer's disease – AD) có thể làm trí nhớ, khả năng suy nghĩ và sinh hoạt hằng ngày suy giảm dần. Suy giảm nhận thức nhẹ (Mild Cognitive Impairment – MCI) là tình trạng cần được theo dõi, bởi những người có cùng chẩn đoán ban đầu vẫn có thể diễn biến khác nhau: một số tiến triển thành sa sút trí tuệ, một số ổn định, còn một số cải thiện [2, 3]. Vì thế, nhận biết người bệnh đang ở tình trạng nào và dự báo họ có thể diễn biến ra sao là hai việc khác nhau; khóa luận tập trung vào việc thứ hai, tức là dùng thông tin đã thu thập qua các lần khám để xếp hạng người nào có nguy cơ tiến triển sớm hơn.


Khi theo dõi một người qua nhiều lần khám, ta có thể xem cả tình trạng của họ lẫn những thay đổi xảy ra theo thời gian. MRI cấu trúc cho thấy hình ảnh giải phẫu não; radiomics chuyển hình dạng, độ sáng và kết cấu của ảnh thành các đặc trưng có thể đo lường; còn các thông tin lâm sàng mô tả khả năng nhận thức và sinh hoạt [4]. Khi được ghép đúng cách, các nguồn thông tin này có thể bổ sung cho nhau, nhưng chúng cũng có thể lặp lại cùng một thông tin, khác thang đo hoặc chứa nhiễu; do đó, khóa luận kiểm tra lợi ích của việc kết hợp dữ liệu bằng thực nghiệm thay vì mặc định

ràng càng có nhiều đầu vào thì mô hình càng tốt.

1.2 Phát biểu bài toán

Đề tài *Longitudinal Learning with Tensor Fusion for Predicting Progression of Alzheimer's Disease* xây dựng mô hình dự báo nguy cơ tiến triển cho nhóm người bị MCI trong dữ liệu của Alzheimer's Disease Neuroimaging Initiative (ADNI) [5]. Mỗi người có ba lần chụp MRI được chọn trong 18 tháng đầu kể từ lần khám ban đầu, cùng các đặc trưng radiomics và thông tin lâm sàng được ghép với từng lần chụp. Mô hình đưa ra một điểm nguy cơ liên tục: điểm càng cao thì nguy cơ tương đối theo mô hình càng lớn, nhưng đây không phải phần trăm khả năng mắc AD và cũng không phải chẩn đoán AD.

Chọn 3 MRI trong cửa sổ 18 tháng: $\text{baseline} \leq s_1 < s_2 < s_3 \leq L$



Hình 1.1: Sơ đồ chọn ba lần chụp MRI trong 18 tháng kể từ lần khám ban đầu. L là ngày kết thúc khoảng thời gian này, bằng ngày khám ban đầu cộng 18 tháng theo lịch; đây là mốc quyết định người bệnh có được chọn vào nhóm nghiên cứu hay không. p là ngày chụp MRI thứ ba và là mốc bắt đầu tính thời gian đến biến cố, nên $p \leq L$. Sau L , biến cố được ghi nhận khi MMSE < 24 hoặc CDR-global ≥ 1 ; đây là tiêu chí dựa trên ngưỡng điểm, không phải chẩn đoán AD đã được xác nhận. o là ngày xảy ra biến cố hoặc ngày theo dõi hợp lệ cuối cùng, và số năm theo dõi được tính bằng số ngày từ p đến o chia cho 365.25. Thông tin lâm sàng được ghép từ lần đo gần nhất trong vòng 90 ngày trước hoặc sau ngày MRI, nên đôi khi được thu thập sau khi chụp ảnh.

Hình 1.1 có hai mốc cần phân biệt. L là ngày khép lại khoảng 18 tháng dùng để chọn nhóm nghiên cứu, còn p là ngày chụp MRI thứ ba và là điểm bắt đầu tính thời gian đến biến cố; trong bộ dữ liệu này, $p \leq L$. Nói cách khác, L quyết định ai được đưa vào nhóm nghiên cứu, còn p cho biết mô hình bắt đầu tính thời gian từ ngày nào. Sau L , biến cố được ghi nhận ở lần đầu tiên người bệnh có $\text{MMSE} < 24$ hoặc $\text{CDR-global} \geq 1$; đây là *dấu hiệu thay thế dựa trên điểm số*, chứ không khẳng định người đó đã được chẩn đoán AD hoặc đã được xác nhận bệnh bằng dấu ấn sinh học. Nếu người bệnh đạt một trong hai ngưỡng, chỉ báo biến cố $\delta = 1$; nếu họ chưa đạt ngưỡng cho đến lần theo dõi hợp lệ cuối cùng, $\delta = 0$ và dữ liệu được xem là chưa ghi nhận biến cố trong thời gian theo dõi. Vì vậy, $\delta = 0$ không có nghĩa là người đó sẽ không tiến triển về sau.

Khóa luận phân tích dữ liệu đã được thu thập trước đó, và thông tin lâm sàng được ghép theo ngày gần nhất trong khoảng 90 ngày trước hoặc sau mỗi lần MRI. Vì khoảng ghép kéo dài cả về trước lẫn sau, một số thông tin có thể được ghi nhận sau ngày chụp MRI thứ ba; do đó, việc chia dữ liệu theo từng người và chỉ tính các bước tiền xử lý trên tập huấn luyện giúp hạn chế lẫn thông tin giữa các nhóm, nhưng chưa chứng minh rằng mọi đầu vào đều đã có sẵn đúng tại ngày p nếu áp dụng mô hình trong thực tế. Chương 3 mô tả cách ghép dữ liệu, còn Chương 5 bàn thêm giới hạn này.

Về cách kết hợp dữ liệu, concatenation chỉ nối các nhóm đặc trưng cạnh nhau rồi để các lớp tiếp theo tự học mối liên hệ; còn phép tích ngoài (outer product) tính trực tiếp tương tác giữa từng cặp đặc trưng, nhưng số phép tính và tham số có thể tăng nhanh [6]. Vì vậy, khóa luận lần lượt kiểm tra liệu có cần tạo tương tác riêng hay không, liệu có thể dùng phương pháp CP để biểu diễn gọn phần tương tác hay không, và liệu có cần giữ tương tác trực tiếp giữa mọi cặp dữ liệu hay không.

1.3 Câu hỏi nghiên cứu

Các câu hỏi trong Bảng 1.1 đi theo từng bước phát triển mô hình, và mỗi câu hỏi được gắn với một phép so sánh cụ thể. Kết quả chỉ phản ánh nhóm người bệnh và cách đánh giá được dùng trong khóa luận, nên không có nghĩa là một kiến trúc sẽ luôn tốt hơn trên mọi bộ dữ liệu.

Các thử nghiệm ban đầu lần lượt chuyển từ MRI đơn sang MRI theo thời gian, rồi kết hợp nhiều loại dữ liệu; tuy nhiên, trong quá trình thăm dò đó, một số phần khác như bộ trích đặc trưng, mô-đun xử lý chuỗi và cách chia batch cũng thay đổi. Vì vậy, không thể quy toàn bộ chênh lệch kết quả giữa các giai đoạn cho riêng việc thêm một loại dữ liệu hay đổi cách kết hợp; để đánh giá từng thành phần, khóa luận dựa nhiều

hơn vào các phép so sánh chỉ thay đổi một yếu tố, các thử nghiệm lần lượt bỏ từng thành phần và bài đánh giá chuẩn hóa.

Bảng 1.1: Câu hỏi nghiên cứu định hướng các thực nghiệm.

Mã	Câu hỏi nghiên cứu
RQ1	Dùng nhiều lần MRI theo thời gian có giúp dự báo tốt hơn chỉ dùng MRI ở một lần khám trong nhóm nghiên cứu này không?
RQ2	Khi nối các đặc trưng lại với nhau, radiomics và thông tin lâm sàng bổ sung được gì ngoài MRI?
RQ3	Nếu giữ các phần khác của quy trình như nhau, tạo tương tác riêng giữa từng cặp dữ liệu có tốt hơn chỉ nối các đặc trưng không?
RQ4	Dùng dạng CP để làm gọn phần tính tương tác giúp giảm số tham số đến đâu, và kết quả trên tập kiểm định thay đổi như thế nào?
RQ5	Cổng điều tiết, hệ số của từng nhánh kết nối và nhánh giữ lại đặc trưng ban đầu đóng góp ra sao; có thể bỏ tương tác trực tiếp giữa radiomics và thông tin lâm sàng hay không?

1.4 Mục tiêu nghiên cứu

Mục tiêu chung là xây dựng và phân tích một quy trình dùng nhiều lần khám cùng nhiều loại dữ liệu để dự báo tiến triển MCI, đồng thời chọn cách kết hợp dữ liệu dựa trên kết quả thử nghiệm. Cụ thể, khóa luận thực hiện các việc sau:

1. Tạo nhóm người có đủ ba lần chụp MRI, xác định rõ tiêu chí ghi nhận biến cố và trường hợp chưa thấy biến cố; chia dữ liệu theo từng người và chỉ học bước chuẩn hóa từ tập huấn luyện.
2. So sánh mô hình dùng một lần MRI, nhiều lần MRI theo thời gian và cả MRI, radiomics cùng thông tin lâm sàng để xem thời gian và mỗi loại dữ liệu bổ sung ích lợi gì.
3. Tạo tương tác riêng giữa từng cặp MRI–radiomics, MRI–lâm sàng và radiomics–lâm sàng, rồi đưa các đặc trưng mới này trở lại mô hình bằng cơ chế điều tiết.
4. So sánh cách tính đầy đủ các tương tác với cách biểu diễn gọn bằng CP, rồi lần lượt bỏ từng thành phần để xem thành phần nào thực sự cần thiết.
5. Chọn mô hình dựa trên tập kiểm định, nhiều lần chạy với cách khởi tạo khác nhau

và các bài đánh giá chuẩn hóa; giữ riêng tập đánh giá cuối cùng, không dùng tập này để chọn mô hình.

1.5 Đóng góp của khóa luận

Đóng góp của khóa luận là xây dựng quy trình kết hợp dữ liệu và kiểm tra từng phần của mô hình trước khi chọn kiến trúc cuối:

1. Kết hợp MRI 3D, radiomics và thông tin lâm sàng qua nhiều lần khám; T-LSTM theo dõi thay đổi theo thời gian, attention nhấn mạnh thông tin quan trọng, còn mô hình Cox dùng để xếp hạng nguy cơ biến cố.
2. Tạo tương tác cho từng cặp dữ liệu, rồi đưa chúng trở lại mô hình qua cổng điều tiết phụ thuộc đầu vào và hệ số riêng cho mỗi nhánh. Ý tưởng có tham khảo các nghiên cứu về dùng cổng để giữ thông tin cũ và điều chỉnh mức đóng góp của thông tin mới, còn công thức cụ thể do khóa luận xây dựng [7, 8].
3. Dùng phương pháp CP, tức cách biểu diễn khối hệ số nhiều chiều (tensor trọng số) bằng các phần gọn hơn, để giảm số hệ số của lớp tương tác; cách này không phân rã dữ liệu của từng người bệnh.
4. Chọn **RC-Free Pairwise Fusion** sau khi lần lượt bỏ từng thành phần để so sánh. Mô hình vẫn dùng đủ MRI, radiomics và thông tin lâm sàng, nhưng không tạo tương tác trực tiếp giữa radiomics và lâm sàng.
5. So sánh các mô hình trên cùng cách chia dữ liệu qua ba lần chạy, rồi xem độ dao động kết quả và số tham số để cân nhắc giữa độ phức tạp với hiệu quả dự báo.

CP được chọn sau khi so sánh, còn RC-Free được giữ lại sau khi thử bỏ từng thành phần. Kết quả trên tập kiểm định chỉ phản ánh nhóm nghiên cứu hiện tại; đánh giá cuối cùng trên tập dữ liệu giữ riêng chưa được thực hiện.

1.6 Cấu trúc khóa luận

Khóa luận gồm năm chương: Chương 2 trình bày kiến thức nền về dự báo MCI, thời gian đến biến cố và kết hợp dữ liệu; Chương 3 mô tả cách chọn người tham gia, xử lý dữ liệu và xây dựng mô hình. Chương 4 trình bày các thí nghiệm và kết quả, còn Chương 5 bàn về ý nghĩa, giới hạn, hướng phát triển và kết luận.

Chương 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 MCI và tiến triển Alzheimer

MCI mô tả suy giảm nhận thức vượt mức kỳ vọng theo tuổi nhưng chưa làm mất tính độc lập như sa sút trí tuệ. Đây là trạng thái không đồng nhất về nguyên nhân và diễn biến; chỉ một phần người bệnh tiến triển sang AD [2]. Khái niệm lâm sàng này cũng cần được phân biệt với định nghĩa AD theo các dấu ấn sinh học trong khung nghiên cứu NIA-AA [3]. Khóa luận dùng nhãn tiến triển vận hành của project, không coi điểm nguy cơ do mạng sinh ra là bằng chứng xác nhận bệnh lý AD.

Trong nghiên cứu tiên lượng, câu hỏi là một sự kiện sẽ được ghi nhận khi nào sau giai đoạn quan sát. Ba visit có thể cho biết cùng một đặc điểm não đang ổn định hay thay đổi; MRI, radiomics và lâm sàng cung cấp những góc nhìn khác nhau về quá trình đó. Cơ sở dữ liệu ADNI hỗ trợ khảo sát các tín hiệu hình ảnh, lâm sàng và nhận thức theo thời gian [5]. Tuy nhiên, điều kiện phải có đủ chuỗi visit cũng làm cohort nghiên cứu khác với toàn bộ người MCI, đặc biệt với những người tiến triển sớm hoặc thiếu theo dõi.

2.2 Mô hình dọc và phân tích sống còn

2.2.1 Sự kiện, kiểm duyệt và mô hình Cox

Gọi T_i là thời gian quan sát và $\delta_i \in \{0, 1\}$ là chỉ báo sự kiện. Với kiểm duyệt phải, $\delta_i = 0$ chỉ cho biết chưa quan sát sự kiện đến thời điểm kết thúc theo dõi. Phân tích sống còn giữ lại thông tin thời gian và trạng thái kiểm duyệt; phân loại nhị phân tại một cửa sổ cố định trả lời một câu hỏi khác.

Mô hình Cox proportional hazards biểu diễn hazard của bệnh nhân i như sau [9]:

$$h_i(t) = h_0(t) \exp(\eta_i), \quad (2.1)$$

trong đó $h_0(t)$ là baseline hazard và η_i là log-risk. DeepSurv là một ví dụ về cách dùng mạng neural để học log-risk phi tuyến trong mô hình Cox [10]. Trong khóa luận, η_i được thay bằng đầu ra của survival head. Chỉ số này xếp hạng nguy cơ; để có xác suất tiến triển theo một thời hạn còn cần ước lượng baseline survival và đánh giá calibration.

Với risk set $\mathcal{R}(t_i)$ gồm những người còn được theo dõi tại t_i , trường hợp không có ties cho negative partial log-likelihood

$$\mathcal{L}_{\text{Cox}} = - \sum_{i:\delta_i=1} \left(\eta_i - \log \sum_{j \in \mathcal{R}(t_i)} \exp(\eta_j) \right). \quad (2.2)$$

Các sự kiện trùng thời gian được xử lý bằng xấp xỉ Breslow [11]; biểu thức nhóm ties của implementation được trình bày ở Chương 3. Harrell C-index đo khả năng sắp xếp đúng thứ tự trên các cặp có thể so sánh [12]. C-index đánh giá phân biệt, không tự chứng minh calibration hoặc ích lợi lâm sàng; quy tắc xử lý ties cũng cần thống nhất khi so sánh.

Landmarking là cách đặt một mốc thời gian để xét ai còn đủ điều kiện được theo dõi trước khi dự báo kết cục tiếp theo [13]. Trong khóa luận, L là ngày kết thúc khoảng chọn mẫu, bằng ngày khám ban đầu cộng 18 tháng theo lịch; còn p là ngày MRI thứ ba và là mốc bắt đầu tính thời gian. Chỉ những người chưa chạm ngưỡng tiến triển đến hết L mới được chọn, nên kết quả phản ánh riêng nhóm này. Thông tin lâm sàng ghép trong vòng 90 ngày có thể được ghi sau MRI, vì vậy chưa chắc đã có sẵn tại ngày p .

2.2.2 T-LSTM và attention theo visit

Long Short-Term Memory (LSTM) dùng trạng thái bộ nhớ và các gate để tổng hợp thông tin trong chuỗi [14]; khoảng thời gian không đều giữa hai lần khám không tự được mã hóa chỉ bằng thứ tự visit. Time-Aware LSTM (T-LSTM) sử dụng Δt để điều chỉnh một thành phần bộ nhớ theo thời gian đã trôi qua [15]. Đây là cơ chế phù hợp với khoảng cách visit không đều; mức lợi ích so với baseline vẫn phải được kiểm tra trên dữ liệu cụ thể.

Attention tổng hợp các hidden state h_t bằng trọng số học được. Khóa luận dùng một phép chấm điểm cộng theo tinh thần additive attention [16]:

$$e_t = \mathbf{v}^\top \tanh(W_h h_t + b_h), \quad \alpha_t = \frac{\exp(e_t)}{\sum_k \exp(e_k)}, \quad z = \sum_t \alpha_t h_t. \quad (2.3)$$

Trọng số α_t mô tả cách mô hình tổng hợp visit trong lần suy luận đó; bản thân chúng không đủ để suy ra tầm quan trọng nhân quả của một lần khám.

2.3 Thông tin đa phương thức

2.3.1 MRI cấu trúc và biểu diễn học sâu

Convolutional Neural Network (CNN) học bộ lọc cục bộ với trọng số dùng chung trên ảnh [17]. CNN 3D mở rộng phép tích chập sang ba chiều; C3D là một công trình nền tảng cho đặc trưng không gian-thời gian trong video [18]. Với MRI thể tích, cả ba trục đều là trục không gian, còn các visit được xử lý bởi mô hình thời gian riêng. ResNet sử dụng các kết nối residual để học phần hiệu chỉnh trên một nhánh truyền thông tin gốc [19]. MedicalNet/Med3D cung cấp hướng dẫn huấn luyện và transfer learning cho ảnh y tế 3D [20]. Khóa luận khảo sát các baseline MRI trước khi cố định cấu hình encoder cho các so sánh fusion có kiểm soát.

Batch normalization chuẩn hóa theo thống kê mini-batch trong backbone [21]; layer normalization dùng thống kê trên biểu diễn của từng mẫu và được sử dụng sau hợp nhất [22]. ReLU [23] và GELU [24] là các hàm kích hoạt được dùng theo từng khối của implementation. Những thành phần này hỗ trợ tối ưu, không phải các đóng góp mới của khóa luận.

2.3.2 Vision Transformer và biểu diễn ảnh 3D

Transformer sử dụng attention để học quan hệ giữa các token [25]. Vision Transformer (ViT) áp dụng ý tưởng này cho chuỗi patch ảnh [26]. Khi mở rộng sang thể tích, patch có ba chiều và attention có thể liên kết những vùng xa nhau; UNETR minh họa encoder Transformer cho ảnh y tế 3D trong tác vụ segmentation [27]. Đây là nền tảng của hướng ViT 3D, còn khả năng tiên lượng tiến triển cần được đánh giá bằng một protocol riêng.

CrossFormer gốc học cross-scale embeddings và attention ở khoảng cách ngắn/dài trên ảnh 2D [28]. Các track so sánh trong project dùng bản thích nghi CrossFormer3D Tiny cho MRI thể tích. Tên này được giữ trong phần thực nghiệm để xác định đúng backbone đã khảo sát; các paper ViT và UNETR cung cấp cơ sở lý thuyết, còn encoder của kiến trúc cuối là ResNet-18 3D khởi tạo từ MedicalNet.

2.3.3 Radiomics và giảm chiều

PyRadiomics trích xuất các descriptor định lượng từ ảnh và vùng quan tâm, bao gồm hình dạng, cường độ và kết cấu [4]. Radiomics và CNN embedding cùng bắt nguồn từ MRI nhưng dùng hai cách biểu diễn khác nhau; vì vậy chúng có thể vừa bổ sung vừa trùng lặp thông tin. Principal Component Analysis (PCA) tạo những hướng tuyến tính trực giao tối đa hóa phương sai và được dùng để giảm chiều đầu vào [29]. PCA không tối ưu trực tiếp khả năng tiên lượng; số thành phần và mọi thống kê chuẩn hóa phải được fit từ training split trong quy trình đánh giá.

2.3.4 Biến lâm sàng và observedness masks


Các thước đo như MMSE và CDR cung cấp thông tin về nhận thức và mức suy giảm chức năng [30, 31]. Clinical branch trong project nhận giá trị sau tiền xử lý cùng observedness masks. Mask cho phép mô hình phân biệt một giá trị được quan sát với một giá trị được điền thay thế. Tuy nhiên, mask không khắc phục sai lệch do cơ chế thiếu dữ liệu hoặc việc đo sau thời điểm dự báo; quy tắc căn chỉnh vẫn phải được báo cáo riêng.

2.4 Các chiến lược hợp nhất đa phương thức

Học đa phương thức cần phân biệt biểu diễn, căn chỉnh và hợp nhất thông tin [32]. Hình 2.1 tổ chức các lựa chọn fusion theo hai câu hỏi: tương tác được biểu diễn như thế nào và mức đóng góp được kiểm soát như thế nào. Các nhóm không loại trừ nhau; chẳng hạn một lớp song tuyến có thể dùng CP cho trọng số và gated residual cho đầu ra.

Concatenation nối các vector và để MLP phía sau học quan hệ. **Tích từng phần** tạo tương tác đơn giản sau khi các vector được đưa về kích thước tương thích, nhưng không liệt kê đầy đủ mọi cặp chiều. **Bilinear/outer-product fusion** mô hình hóa trực tiếp tích chéo giữa các chiều; Tensor Fusion Network là một ví dụ tiêu biểu trong học đa phương thức [6]. **Low-rank fusion** ràng buộc cấu trúc trọng số để giảm độ phức tạp [33]. **Adaptive/gated fusion** bổ sung một cơ chế chọn mức đóng góp phụ thuộc đầu vào.

Với cohort nhỏ, biểu diễn phong phú hơn cũng có thể làm tăng phương sai ước lượng. Vì vậy, trình tự của project là thiết lập concatenation, khảo sát pairwise tương



Hình 2.1: Các chiến lược fusion liên quan đến khóa luận. Concatenation là điểm xuất phát; bilinear/outer-product biểu diễn tương tác tường minh; low-rank factorization kiểm soát số tham số; gate và residual điều chỉnh cách bổ sung tương tác vào biểu diễn gốc. CP và gated residual là hai lựa chọn có thể kết hợp trong cùng khối fusion.

tác đầy đủ, rồi mới thay lỗi bằng CP và kiểm tra khả năng rút gọn topology. Đây là các giả thuyết thiết kế cần bằng chứng validation, không phải một bảng xếp hạng cố định giữa các loại fusion.

2.5 Tương tác song tuyến và phân rã tensor

Với $x \in \mathbb{R}^{d_x}$ và $y \in \mathbb{R}^{d_y}$, outer-product $xy^\top$ chứa mọi tích $x_i y_j$. Flatten ma trận này rồi dùng một lớp linear tương đương ánh xạ song tuyến

$$h_k = \sum_{i=1}^{d_x} \sum_{j=1}^{d_y} W_{kij} x_i y_j + b_k, \quad (2.4)$$

với tensor trọng số $W \in \mathbb{R}^{d_o \times d_x \times d_y}$. Lỗi trọng số chứa $d_o d_x d_y$ tham số, chưa tính bias.

CP decomposition biểu diễn tensor như tổng các tensor hạng một [34, 35]. Áp

dùng cấu trúc này cho *tensor trọng số của lớp song tuyến*, với rank Q , cho

$$W_{kij} \approx \sum_{q=1}^Q O_{kq} A_{iq} B_{jq}, \quad h = O[(A^\top x) \odot (B^\top y)] + b. \quad (2.5)$$

Các factor A , B và O được học; không cần dựng outer-product tường minh. Lỗi trọng số còn $Q(d_x + d_y + d_o)$ tham số. Biểu thức này là cơ sở cho phép thay thế controlled CP của khóa luận; số đếm trong implementation còn tính các bias và được báo cáo riêng ở Chương 4.

Low-rank Multimodal Fusion khai thác các factor theo phương thức [33], trong khi MUTAN dùng cấu trúc Tucker cho bilinear fusion [36]. Các công trình này cung cấp cơ sở về tham số hóa tensor; chúng không chứng minh trực tiếp CP sẽ cải thiện tiên lượng AD. Đặc biệt, trong mô hình của khóa luận, CP factorizes the bilinear interaction weight tensor; dữ liệu MRI/radiomics/lâm sàng của một bệnh nhân không bị phân rã CP trong forward pass.

2.6 Gated residual fusion

Ryumina và cộng sự dùng một phương thức neo, gate phụ thuộc đầu vào và residual hiệu chỉnh trong Text Residual Fusion [7]. Liu và cộng sự đưa skeleton vào nhánh RGB qua gated residual với hệ số scale cố định $\alpha = 0.5$ [8]. Đây là hai nghiên cứu ở các tác vụ khác với tiên lượng AD, cung cấp cảm hứng thiết kế về điều tiết đóng góp và scaling.

Lấy cảm hứng từ gated residual modulation trong [7] và explicit residual scaling trong [8], khóa luận xây dựng cập nhật residual riêng cho từng route:

$$Z_d = \text{LN} \left[U_d + \sum_{p \in \mathcal{P}(d)} \lambda_{p \rightarrow d} g_{p \rightarrow d} E_{p \rightarrow d} \right]. \quad (2.6)$$

U_d là biểu diễn gốc của phương thức đích ở không gian residual; $E_{p \rightarrow d}$ là tương tác đã chiếu về cùng không gian; $g_{p \rightarrow d}$ thay đổi theo đầu vào của bệnh nhân-visit; $\lambda_{p \rightarrow d}$ là scalar học được, dùng chung cho route qua các mẫu. Hai bài báo không đề xuất nguyên vẹn công thức này. Khóa luận thích nghi ý tưởng thành định tuyến pairwise theo đích, đồng thời thay scale cố định bằng tham số học theo route.

Identity residual giữ một đường truyền cho thông tin phương thức gốc; gate và scale kiểm soát phần hiệu chỉnh nhưng không tự bảo đảm cải thiện hiệu năng. Layer normalization [22] được áp dụng sau tổng residual. Dropout [37] giúp regularize các

MLP; tối ưu dùng AdamW [38], phát triển từ Adam [39] với weight decay tách khỏi cập nhật gradient. Vai trò thực nghiệm của gate, scale và residual được đánh giá bằng ablation.

2.7 Các nghiên cứu liên quan

Các công trình trong Bảng 2.1 có sự khác biệt về cohort, thời điểm dự báo, nhãn và metric. Do đó, bảng dùng để nhận diện lựa chọn phương pháp và khoảng trống, không so sánh trực tiếp số hiệu năng giữa các bài báo với thesis.

Bảng 2.1: Các nghiên cứu liên quan và vị trí của khóa luận. Hai công trình cuối có tác vụ khác với survival ranking, nhưng cung cấp góc nhìn về cấu trúc tensor và fusion thích nghi.

Nghiên cứu	Đầu vào và tác vụ	Liên hệ phương pháp
Li-Fan (2019) [40]	MRI hồi hải mã baseline; nhận thức đọc một năm; tiên lượng tiến triển.	Mạng hồi tiếp kết hợp tín hiệu thời gian với MRI.
Ding (2023) [41]	Biến nhân khẩu, nhận thức và đo đặc ảnh tại năm mốc; chuyển đổi hai năm.	LSTM đọc so với random forest tại index exam.
Bapat (2024) [42]	MRI 3D và nhận thức đọc; chuyển đổi trong bốn năm.	CNN 3D trích đặc trưng, concatenation rồi CNN 1D.
Aghajanian (2025) [1]	MRI T1 đọc và radiomics; mô hình sống còn.	CNN-T-LSTM-attention; nguồn baseline trực tiếp của project.
Zhang (2023) [43]	Đặc điểm cấu trúc não đọc; dự báo MMSE/ADAS-Cog.	Tensor multi-task và ensemble; khác CP trọng số pairwise.
Li (2026) [44]	sMRI và clinical đọc; phân loại NC/MCI/AD.	Brain latent diffusion và MoE điều tiết các biểu diễn.

Aghajanian và cộng sự sử dụng 228 người MCI, mỗi người có ba MRI T1 trong 18 tháng; chuỗi CNN embedding được đưa vào T-LSTM có attention. Radiomics không cải thiện nhất quán, và thảo luận của bài báo lưu ý vai trò của huấn luyện hai bước và

ensemble [1]. Vì vậy, khi chuyển ý tưởng vào project hiện tại, cần phân biệt lợi ích của thông tin dọc với lợi ích của encoder, quy trình huấn luyện và cơ chế fusion.

Zhang và cộng sự dự báo điểm nhận thức bằng tensor multi-task learning và ensemble [43]; công trình này giúp hình thành ý tưởng dùng cấu trúc tensor trong giai đoạn tìm hiểu. Khóa luận sau đó chuyển trọng tâm sang CP cho *trọng số* tương tác song tuyến trong pipeline sống còn. Li và cộng sự dùng MoE cho phân loại trạng thái chẩn đoán [44]; cơ chế thích nghi có liên hệ với fusion, nhưng tác vụ này không tương đương với dự báo thời gian tiến triển.

2.8 Khoảng trống nghiên cứu

Khóa luận đặt ba câu hỏi trong cohort và pipeline hiện tại: tương tác tường minh bổ sung gì cho concatenation; CP có giữ hiệu năng hữu ích khi chỉ thay lõi bilinear và giữ các khối khác; và cặp trực tiếp nào cần giữ sau factorization? Chương tiếp theo triển khai kiến trúc và residual routing thích nghi; các so sánh có kiểm soát cùng validation ở Chương 4 kiểm tra các giả thuyết này.

Chương 3

Phương pháp

Chương này trình bày cách xây dựng mẫu nghiên cứu, quá trình phát triển kiến trúc và hoạt động của mô hình cuối. Ký hiệu M , R và C lần lượt chỉ embedding MRI, radiomics và clinical tại một visit. Các khối fusion được dùng chung giữa ba visits; mô hình thời gian sau đó tổng hợp chuỗi thành một điểm nguy cơ ở cấp bệnh nhân. Shape được trình bày ở Bảng 3.1, 3.2, 3.3 và 3.5; kết quả đánh giá ở Chương 4.


3.1 Thiết kế nghiên cứu và xây dựng dữ liệu

3.1.1 Tiêu chí chọn mẫu và ba visits

Dữ liệu được lấy từ Alzheimer’s Disease Neuroimaging Initiative (ADNI), một nghiên cứu dọc đa trung tâm về suy giảm nhận thức và AD [5, 45]. Pipeline liên kết định danh bệnh nhân PTID–RID và chọn baseline MCI sớm nhất có ngày hợp lệ, mã diagnosis bằng 2 và visit code b1 trong ADNI1, ADNIGO hoặc ADNI2. Với bệnh nhân i , đặt b_i là ngày baseline và $L_i = b_i + 18$ tháng lịch là *mốc xét điều kiện cohort*.

Bệnh nhân bị loại nếu có diagnosis AD trong DXSUM, $MMSE < 24$ hoặc $CDR\text{-}global \geq 1$ tại hoặc trước L_i . Sau L_i , cần ít nhất một đánh giá MMSE/CDR hợp lệ để xác định event hoặc censoring. Đây là một cohort được xây dựng hồi cứu và điều kiện hóa trên việc chưa tiến triển qua cửa sổ 18 tháng; nó không đại diện cho mọi bệnh nhân MCI tại baseline.

MRI được chọn trong khoảng $[b_i, L_i]$. Các scan gần nhau được nhóm thành time-point theo cửa sổ hai tháng tính từ scan đầu nhóm. Trong mỗi nhóm, scan primary được ưu tiên trước repeat, rồi đến processing rank và image ID. Nếu có hơn ba timepoints, giữ scan đầu, scan cuối và scan trung gian gần trung điểm thời gian nhất. Metadata QC chính thức không liên kết được với image ID của danh sách MRI hiện có, nên lựa chọn sử dụng processing fallback đã ghi trong manifest. Quy trình tạo ra ba ngày MRI tăng nghiêm ngặt $s_{i1} < s_{i2} < s_{i3} \leq L_i$.



Hình 3.1: Quy trình xây dựng cohort từ metadata ADNI đến mẫu ba visits và phép chia theo RID. Số người ở các bước là số liệu của cohort đã đóng băng; MRI, radiomics và clinical được liên kết theo cùng định danh visit. Scaler, PCA và imputation chỉ fit trên train, rồi áp dụng nguyên vẹn cho validation/test.

Hình 3.1 tóm tắt quá trình lọc từ 899 người có MRI và liên kết định danh thành công xuống 359 người với đúng ba MRI mỗi người, tương ứng 1 077 MRI. Cohort gồm 106 events và 253 trường hợp censored; phân bố baseline phase là ADNI1: 78, ADNIGO: 80 và ADNI2: 201. Không điều chỉnh tiêu chí để ép cỡ mẫu giống nghiên cứu tham chiếu.

3.1.2 Event, censoring và mốc tính thời gian

Sau L_i , event được xác định ở ngày đầu tiên có MMSE hợp lệ < 24 hoặc CDR-global hợp lệ ≥ 1 . Nếu không có event theo quy tắc này, censoring diễn ra ở ngày MMSE/CDR hợp lệ cuối cùng. Những giá trị không hợp lệ hoặc sentinel không tạo event. Endpoint này là *proxy tiến triển dựa trên ngưỡng thang điểm*; nó không đòi hỏi

một diagnosis AD sau L_i và không xác nhận AD bằng biomarker.

Ngày tham chiếu dự báo của mô hình là $p_i = s_{i3}$, tức MRI được chọn cuối cùng. Nếu o_i là ngày event hoặc censoring, nhãn survival là

$$t_i = \frac{o_i - p_i}{365.25}, \quad \delta_i = \begin{cases} 1, & \text{có event,} \\ 0, & \text{censored.} \end{cases} \quad (3.1)$$

Do $p_i \leq L_i$, ngày MRI cuối và mốc xét điều kiện cohort không nhất thiết trùng nhau. Nhãn dùng thời gian từ p_i , trong khi mẫu đã được chọn với điều kiện không tiến triển đến L_i . Khoảng $[p_i, L_i]$ và điều kiện sống sót qua cửa sổ này phải được giữ rõ khi diễn giải, thay vì coi protocol hiện tại là một đánh giá tiến cứu cho mọi bệnh nhân ngay tại p_i .

3.1.3 Phân chia và bảo vệ quá trình học


Split cố định theo RID gồm 251 training, 54 validation và 54 test; mọi MRI của một người thuộc cùng một split. Số events tương ứng là 74, 16 và 16. Khóa liên kết xuyên modality là (RID, visit_index, image_id, split), với kiểm tra duy nhất và bằng nhau về keyset. Imputer, scaler, loại đặc trưng hằng và PCA đều chỉ fit trên training. Diagnosis, event, ngày outcome và survival time không thuộc tập predictor.

Clinical được ghép với MRI bằng quy tắc frozen: cùng RID, đánh giá hợp lệ gần nhất trong cửa sổ ± 90 ngày; hòa khoảng cách ưu tiên ngày sớm hơn rồi ID nhỏ hơn. Audit nguồn ghi nhận 294 offset MMSE/CDR dương trên các visits, với khoảng offset từ -90 đến $+90$ ngày. Đây là số offset đánh giá được ghép, không phải số bệnh nhân. Vì vậy, bảo vệ train-only và split không đồng nghĩa mọi predictor đã sẵn có vào ngày MRI cuối. Việc dùng clinical sau MRI trong cửa sổ ghép là giới hạn về tính khả dụng khi dự báo tiến cứu, cần kiểm tra bằng protocol chỉ dùng thông tin có trước ngày dự báo ở nghiên cứu tiếp theo.

3.2 Tiền xử lý và biểu diễn từng modality

3.2.1 MRI và shared encoder

Pipeline MRI T1 chuẩn hóa orientation RAS, dùng SynthStrip để tách não [46], đăng ký rigid 6-DOF các visits sau về visit đầu, rồi đăng ký rigid visit đầu về MNI152NLin2009cAsym. Ba MRI của cùng người nằm trên lưới chung $144 \times 144 \times 144$, spacing 1.5 mm isotropic. Ảnh được z-score trong brain mask riêng của volume; voxel



Hình 3.2: Ba nhánh xử lý tại một visit. Khối 3D biểu diễn nhánh volume MRI; pooling và projection tạo vector M 128 chiều. Radiomics qua PCA 16 chiều và MLP tạo R 64 chiều; 9 giá trị clinical và 9 masks tạo C 64 chiều. Các encoder dùng chung trọng số qua ba visits; biến đổi thống kê chỉ fit trên training.

ngoài mask bằng không. Nội suy ảnh là linear và nội suy mask là nearest-neighbor. Pipeline này không bổ sung N4, affine scaling hay nonlinear registration.

Encoder là MONAI ResNet-18 3D dùng chung trọng số giữa visits [19, 47]. Backbone chứa BatchNorm và ReLU [21, 23]; sau global pooling, vector 512 chiều qua Linear 512 → 128, GELU, Dropout 0.20 và LayerNorm để tạo M [22, 24, 37]. Trong kiến trúc cuối, backbone được khởi tạo bằng MedicalNet/Med3D [20], nạp chặt trọng số và BatchNorm buffers của backbone, loại task head pretrained và fine-tune toàn bộ từ epoch đầu. Các mô hình MRI random và pretrained thuộc giai đoạn đối chứng, không phải hai encoder đồng thời trong pipeline cuối.

Bảng 3.1 suy ra kích thước feature map từ constructor thực tế và MONAI 1.5.2¹; đây không phải log forward hooks mới. Implementation xử lý lần lượt từng visit với batch B , stack pooled vectors theo trục visit $T = 3$, rồi áp dụng projection.

¹Mã nguồn phiên bản: <https://github.com/Project-MONAI/MONAI/blob/1.5.2/monai/networks/nets/resnet.py>.

Bảng 3.1: Shape MRI encoder: feature map $[B, C, D, H, W]$ và chuỗi pooled/embedding $[B, T, F]$, với $T = 3$.

Bước	Shape đầu ra
MRI đầu vào	$[B, 1, 144, 144, 144]$
Conv 7^3 , stride 1, padding 3; BN; ReLU	$[B, 64, 144, 144, 144]$
MaxPool 3^3 , stride 2, padding 1	$[B, 64, 72, 72, 72]$
ResNet stage 1: hai basic blocks	$[B, 64, 72, 72, 72]$
Stage 2: block đầu stride 2	$[B, 128, 36, 36, 36]$
Stage 3: block đầu stride 2	$[B, 256, 18, 18, 18]$
Stage 4: block đầu stride 2	$[B, 512, 9, 9, 9]$
Global average pooling; flatten	$[B, 512, 1, 1, 1] \rightarrow [B, 512]$
Stack ba pooled vectors	$[B, 3, 512]$
Linear; GELU; Dropout; LayerNorm	$[B, 3, 128]$

3.2.2 Radiomics

PyRadiomics trích 107 đặc trưng whole-brain từ MRI đã xử lý và mask, gồm shape, first-order, GLCM, GLDM, GLRLM, GLSZM và NGTDM [4]. Protocol deep dùng bin-Count 64. Ba đặc trưng hằng trên training được loại bỏ, còn 104; scaling và PCA giữ ít nhất 99% phương sai chỉ fit trên training [29]. Dữ liệu model-ready có 16 thành phần PCA mỗi visit. Đây là chiều *đầu vào* radiomics; embedding R có 64 chiều sau MLP $16 \rightarrow 128 \rightarrow 64$, GELU, Dropout 0.20 và LayerNorm cuối nhánh.

3.2.3 Clinical và observedness masks

Chín predictor gồm MMSE-total, CDR-global, CDR-sum-of-boxes và sáu miền CDR: memory, orientation, judgment, community affairs, home/hobbies và personal care [30, 31]. Giá trị thiếu được điền bằng median training của visit tương ứng, với median training tổng thể làm fallback, sau đó chuẩn hóa bằng mean và độ lệch chuẩn training. Chín masks riêng dùng 1 cho giá trị quan sát được, 0 cho giá trị thiếu. Ghép giá trị và masks tạo 18 đầu vào cho MLP $18 \rightarrow 64 \rightarrow 64$, GELU, Dropout 0.10 và LayerNorm, sinh $C \in \mathbb{R}^{64}$. Mask giúp phân biệt quan sát thật với giá trị điền; nó không loại bỏ giới hạn của cửa sổ ghép ngày đã nêu ở Mục 3.1.

3.2.4 Thư viện và triển khai

Các mô hình neural được triển khai bằng Python và PyTorch cho tensor, automatic differentiation, tối ưu và huấn luyện trên GPU [48]. MONAI cung cấp backbone ResNet 3D cho ảnh y tế [47]. NumPy xử lý mảng số [49]; pandas phục vụ đọc, ghép và kiểm tra các bảng manifest theo bệnh nhân–visit [50]. NiBabel đọc volume NIfTI và thông tin affine trong các loader MRI.

Tiền xử lý dữ liệu bằng dùng scikit-learn cho scaling và PCA [51]; PyRadiomics trích các descriptor đã nêu ở trên [4]. Baseline Cox elastic-net, Random Survival Forest và đánh giá dữ liệu kiểm duyệt được xây dựng với scikit-survival [52]. Các script kiểm tra tiền xử lý ảnh có sử dụng Matplotlib để trực quan hóa kết quả kiểm tra [53].


Prototype Cox ban đầu có backend TorchSurv tùy chọn [54]. Các phase pairwise được đối chiếu trong khóa luận có implementation Cox/Breslow riêng, với risk set mini-batch và cách xử lý ties được mô tả ở Mục 3.11. Việc trích dẫn thư viện xác định hạ tầng phương pháp; thông số của các mô hình và kết quả thực nghiệm vẫn được xác định từ artifact của từng phase.

3.3 Quá trình phát triển kiến trúc

Kiến trúc được phát triển theo từng câu hỏi nghiên cứu, không bắt đầu với CP hay topology RC-Free hoàn chỉnh. MRI Only khảo sát biểu diễn không gian từ MRI cuối; Longitudinal MRI thêm T-LSTM và attention để xử lý chuỗi. Multimodal Concatenation tiếp theo kiểm tra thông tin bổ sung từ radiomics và clinical bằng phép nối đơn giản. Dynamic Pairwise Fusion đưa vào tương tác tường minh giữa từng cặp modality và định tuyến residual. Variant MedicalNet giữ cơ chế fusion nhưng thay khối tạo backbone, sau đó trở thành reference cho thí nghiệm CP.

Full outer-product tạo tương tác giàu nhưng cần lớp tuyến tính lớn. CP được áp dụng ở bước sau để giảm chi phí của lớp này trong khi giữ các khối còn lại. Fusion ablation tiếp tục kiểm tra gate, scale, identity residual và từng pair. Kết quả validation dẫn tới RC-Free Pairwise Fusion, chỉ giữ MR và MC. Hình 3.3 là chronology thiết kế; các so sánh và mức độ chắc chắn của bằng chứng được trình bày ở Chương 4. Chuỗi milestone ban đầu có khác biệt về protocol batching, nên không được diễn giải toàn bộ thành các đối chứng chỉ thay duy nhất một thành phần.

Bảng 3.3 tách hai encoder đối chứng khỏi ResNet của kiến trúc cuối. Paper CNN



Hình 3.3: Tiến hóa của framework theo các câu hỏi thực nghiệm. CP thay cách tham số hóa interaction core sau khi full outer-product đã được nghiên cứu; topology RC-Free hình thành sau fusion ablation và được kiểm tra tiếp bằng validation nhiều seed.

dùng TensorFlow với MRI 128^3 , stem stride 2 và embedding lấy tại global average pooling *trước* dropout/head CNN. Trong P10 retuned, PCA được fit riêng trên embedding training của từng seed: $K = 38, 69$ và 2 lần lượt cho seed 20260727, 20260728 và 20260729; cấu hình T-LSTM đã chọn có hidden size 64. PCA chỉ center, giữ 99% phương sai, không scaling/whitening. CrossFormer3D Tiny nhận MRI 144^3 channels-first, stem stride 6, rồi đổi sang channels-last. Shape CNN được suy ra từ source; chiều embedding/PCA được xác nhận bằng artifact đã lưu, còn CrossFormer dựa trên source contract và shape tests. Đây không phải phép đo mới bằng forward hooks.

Bảng 3.2: Giao diện shape theo giai đoạn phát triển. Chiều feature tính cho một visit; shape chuỗi giữ $T = 3$. Raw log-risk ở mọi giai đoạn là $[B]$.

Giai đoạn	Biểu diễn trước temporal/head	Patient vector
MRI Only	CNN 512 $\rightarrow$ 128, một visit	$[B, 128]$
Longitudinal MRI	Ba MRI: $[B, 3, 512] \rightarrow [B, 3, 128]$	$[B, 128]$
CrossFormer3D	Pooled 512; P03-X: $[B, 3, 512] \rightarrow [B, 3, 128]$	$[B, 128]$
Multimodal Concat.	$M/R/C : 128/64/64 \rightarrow 256 \rightarrow 128$	$[B, 128]$
Full Pairwise	Pair MR/MC/RC: 64/64/32; readout 256 $\rightarrow$ 128	$[B, 128]$
Paper	CNN 512 $\rightarrow$ PCA $K \rightarrow$ T-LSTM 64	$[B, 64]$
CNN-T-LSTM		
CP Pairwise	Rank 8/8/4; giữ pair outputs 64/64/32	$[B, 128]$
RC-Free / Fixed- λ	Rank MR/MC 8/8; bốn routes; readout 256 $\rightarrow$ 128	$[B, 128]$

Bảng 3.3: Shape các encoder đối chứng. N là batch volume CNN; B là batch bệnh nhân. Ký hiệu s^3 trong shape viết tắt ba trục không gian (s, s, s); thứ tự trục được ghi riêng cho từng khối.

(a) P10: Paper CNN-PCA-T-LSTM		(b) CrossFormer3D Tiny: P02-D	
Bước	Shape đầu ra	Bước	Shape đầu ra
CNN: $[N, D, H, W, C]$		Đầu vào/stem: $[B, C, D, H, W]$	
MRI đầu vào	$[N, 128^3, 1]$	MRI đầu vào	$[B, 1, 144^3]$
Conv 7^3 , stride 2	$[N, 64^3, 64]$	Stem $k = 5/7/9$: mỗi nhánh	$[B, 16, 24^3]$
MaxPool 3^3 , stride 2	$[N, 32^3, 64]$	Concat ba nhánh	$[B, 48, 24^3]$
Residual stage 1	$[N, 32^3, 64]$	Projection 1×1	$[B, 64, 24^3]$
Stage 2	$[N, 16^3, 128]$	Permute; LN; GELU	$[B, 24^3, 64]$
Stage 3	$[N, 8^3, 256]$	Các stages: $[B, D, H, W, C]$	
Stage 4	$[N, 4^3, 512]$	Stage 1: hai blocks	$[B, 24^3, 64]$
GAP, trước dropout	$[N, 512]$	Patch Merge 1	$[B, 12^3, 128]$
Chuỗi ba visits: $[B, T, F]$		Stage 2: hai blocks	$[B, 12^3, 128]$
Group theo RID	$[B, 3, 512]$	Patch Merge 2	$[B, 6^3, 256]$
PCA train-only	$[B, 3, K]$	Stage 3: hai blocks	$[B, 6^3, 256]$
T-LSTM hidden	$[B, 3, 64]$	Patch Merge 3	$[B, 3^3, 512]$
Hidden/cell cuối	$[B, 64]$	Stage 4; final LN	$[B, 3^3, 512]$
Attention: projection	$[B, 3, 64]$	Masked spatial pool	$[B, 512]$
Scores; weights	$[B, 3, 1]$	Identity adapter	$[B, 512]$
Weighted context	$[B, 64]$	Head: Linear; GELU; dropout	$[B, 128]$
Linear risk; squeeze	$[B, 1] \rightarrow [B]$	Linear risk; squeeze	$[B, 1] \rightarrow [B]$

3.4 Multimodal Concatenation baseline

Tại visit t , baseline nối ba embedding:

$$F_t = \text{Readout}(M_t \parallel R_t \parallel C_t), \quad M_t \parallel R_t \parallel C_t \in \mathbb{R}^{256}, \quad F_t \in \mathbb{R}^{128}. \quad (3.2)$$

Readout gồm Linear $256 \rightarrow 128$, GELU, Dropout 0.20 và LayerNorm. Chuỗi ba F_t đi qua temporal stack và Cox head. Baseline giữ thông tin của cả ba modality nhưng không có bilinear pair block hoặc route riêng, nên tạo mốc so sánh cho câu hỏi về cơ chế interaction.

3.5 Dynamic Pairwise Fusion

Trước khi tạo interaction, các phép chiếu tuyến tính không bias đưa embedding xuống

$$\tilde{M} \in \mathbb{R}^{32}, \quad \tilde{R} \in \mathbb{R}^{32}, \quad \tilde{C} \in \mathbb{R}^{16}. \quad (3.3)$$

Những bottleneck này giảm chiều input nhưng full reference vẫn tạo outer-product tường minh. Với pair input $x \in \mathbb{R}^{d_x}$, $y \in \mathbb{R}^{d_y}$, đặt $v = \text{vec}(xy^\top)$. MR dùng $1024 \rightarrow 128 \rightarrow 64$, MC dùng $512 \rightarrow 128 \rightarrow 64$, RC dùng $512 \rightarrow 64 \rightarrow 32$. Giữa hai Linear của pair có GELU và Dropout 0.10; cuối pair có LayerNorm.

Mỗi pair feature E_k được đưa về hai modality đích bằng các adapter Linear và LayerNorm độc lập. MR và MC có feature 64 chiều, RC có feature 32 chiều. Sáu output adapter cùng chiều với modality đích: (MR $\rightarrow M$) và (MC $\rightarrow M$) là 128; (MR $\rightarrow R$), (RC $\rightarrow R$), (MC $\rightarrow C$) và (RC $\rightarrow C$) là 64. Interaction chỉ diễn ra trong một visit của một bệnh nhân, không nhân chéo người hoặc thời điểm. Hình 3.4 tách rõ ba pair blocks và sáu routes thay vì xem các cạnh ngược là sáu pair khác nhau.

3.6 CP-factorized pairwise interaction


Với full bilinear first layer, hidden output thứ s là

$$h_s = \sum_{i=1}^{d_x} \sum_{j=1}^{d_y} \mathcal{W}_{sij} x_i y_j + b_s, \quad \mathcal{W} \in \mathbb{R}^{d_h \times d_x \times d_y}. \quad (3.4)$$

CP tham số hóa *tensor trọng số của ánh xạ bilinear*, theo dạng low-rank [33, 35]:

$$\mathcal{W}_{sij} \approx \sum_{q=1}^Q O_{sq} A_{iq} B_{jq}. \quad (3.5)$$

Full reference: 3 pair blocks, 6 directed routes




Hình 3.4: Full pairwise graph với ba interaction MR, MC, RC và sáu directed routes về các modality thành viên. Mỗi pair được tạo từ low projections của hai modality, một lần tại cùng patient-visit; hai hướng có adapter và gate riêng. Đây là kiến trúc reference trước khi loại RC.

Trong mô hình này $A \in \mathbb{R}^{d_x \times Q}$, $B \in \mathbb{R}^{d_y \times Q}$ và $O \in \mathbb{R}^{d_h \times Q}$ được học cùng mạng. Không có bước phân rã dữ liệu bệnh nhân bằng CP. Forward tương ứng là

$$u = A^\top x, \quad v = B^\top y, \quad q = u \odot v, \quad (3.6)$$

$$h = Oq + b, \quad E_{xy} = \text{PostMLP}_{xy}(h). \quad (3.7)$$

A và B không bias; bias b của first layer được giữ trong $Oq + b$. Post-MLP vẫn là GELU, Dropout 0.10, Linear $d_h \rightarrow d_o$ và LayerNorm. Vì vậy, controlled CP comparison chỉ thay first interaction transformation, giữ output shape, post-MLP, encoders, routes, gate, scale và temporal stack.



Hình 3.5: Khối 3D biểu diễn tensor trọng số $W \in \mathbb{R}^{d_h \times d_x \times d_y}$ và tổng các tensor rank-one trong CP; đây là phân rã trọng số, không phải dữ liệu bệnh nhân. Forward dùng hai phép chiếu rank Q , tích Hadamard và phép chiếu output, không dùng W hay activation outer-product. Phiên bản CP đủ ba pair có low dimensions MR/MC/RC là 32×32 , 32×16 , 32×16 và ranks 8/8/4; post-MLP giữ nguyên.

Bảng 3.4: Cấu hình CP của full reference và kiến trúc cuối.

Pair	(d_x, d_y)	Rank Q	Hidden d_h	Output d_o	RC-Free
MR	(32, 32)	8	128	64	Giữ
MC	(32, 16)	8	128	64	Giữ
RC	(32, 16)	4	64	32	Loại

Bảng 3.4 ghi rank thực sự được dùng; không có kết quả khảo sát rank rộng được tuyên bố trong khóa luận. First layer full có $d_h d_x d_y + d_h$ tham số; CP có $Q(d_x + d_y + d_h) + d_h$. Lợi ích trực tiếp nằm ở interaction core, trong khi backbone MRI vẫn chiếm phần lớn tổng tham số. Không suy ra mức tăng tốc toàn pipeline chỉ từ công thức tham số.

3.7 Dynamic gated residual routing

Lấy cảm hứng từ gated residual modulation của Ryumina và cộng sự [7] và explicit residual scaling của Liu và cộng sự [8], khóa luận xây dựng cập nhật residual riêng cho từng route. Hai công trình này cung cấp ý tưởng điều tiết và scaling; công thức dưới đây là thiết kế của project, không phải công thức nguyên dạng của các paper.

Với pair k và modality đích d , ký hiệu U_d là embedding modality gốc và

$$\widehat{E}_{k \rightarrow d} = \text{LN}_{k \rightarrow d}(W_{k \rightarrow d}E_k + b_{k \rightarrow d}) \quad (3.8)$$

là feature đã chiếu về chiều đích. Gate dùng cả trạng thái modality và feature route:

$$g_{k \rightarrow d} = \sigma \left(w_{k \rightarrow d}^\top \text{GELU} \left[V_{k \rightarrow d} (\text{LN}_d^{\text{gate}}(U_d) \parallel \widehat{E}_{k \rightarrow d}) + a_{k \rightarrow d} \right] + c_{k \rightarrow d} \right). \quad (3.9)$$

Gate MLP có hidden 32 và output một scalar trong $(0, 1)$ cho mỗi patient-visit; scalar được broadcast trên các feature channels. Các routes dùng sigmoid độc lập, không cạnh tranh bằng softmax. Gate weights được khởi tạo Xavier và biases bằng không.

Scale $\lambda_{k \rightarrow d}$ là scalar học được riêng cho route nhưng dùng chung giữa bệnh nhân và visits. Implementation hiện có khởi tạo $\lambda = 0.1$ và *không ràng buộc dấu*: đây là tham số trực tiếp, không qua softplus. Vì vậy gate biểu diễn mức điều tiết phụ thuộc input, còn λ biểu diễn scale và dấu toàn cục của route; không đồng nhất chúng thành attention weight.


Cập nhật tổng quát của modality là

$$Z_d = \text{LN}_d^{\text{out}} \left(U_d + \sum_{k \in \mathcal{P}(d)} \lambda_{k \rightarrow d} g_{k \rightarrow d} \widehat{E}_{k \rightarrow d} \right). \quad (3.10)$$

$\mathcal{P}(d)$ là các pair còn hoạt động đi vào d . Đường identity dùng trực tiếp U_d , không thêm một phép chiếu identity học được. LayerNorm ở adapter, ở input gate và sau tổng residual là ba phép chuẩn hóa khác nhau [22]. Contribution thực tế phụ thuộc đồng thời λ , gate và norm feature; riêng gate hoặc scale không chứng minh ý nghĩa sinh học hay quan hệ nhân quả.

3.8 RC-Free Pairwise Fusion

Kiến trúc cuối cho nghiên cứu validation là RC-Free CP-Factorized Pairwise Fusion, gọi ngắn là RC-Free Pairwise Fusion. Quyết định bỏ RC được nghiên cứu sau



Hình 3.6: Giải phẫu một route: pair feature qua directed projection, nhân dynamic gate theo patient–visit và global route scale λ , cộng vào đường identity rồi LayerNorm. Gate nhận modality gốc đã chuẩn hóa và directed pair feature; identity giữ nguyên embedding gốc, không thêm projection. Scalar λ không ràng buộc dấu và khởi tạo bằng 0.1.

full CP ablation rồi kiểm tra tiếp bằng nhiều seed; nó không phải giả định được áp đặt từ đầu. RC-Free loại *direct radiomics–clinical pair*, đồng thời vẫn giữ cả ba unimodal branches. MRI trở thành điểm nổi của hai interaction MR và MC.


Đặt $D_{k \rightarrow d} = \lambda_{k \rightarrow d} g_{k \rightarrow d} \hat{E}_{k \rightarrow d}$, các output là

$$M_{\text{out}} = \text{LN}_M^{\text{out}}(M + D_{(\text{MR} \rightarrow M)} + D_{(\text{MC} \rightarrow M)}), \quad (3.11)$$

$$R_{\text{out}} = \text{LN}_R^{\text{out}}(R + D_{(\text{MR} \rightarrow R)}), \quad (3.12)$$

$$C_{\text{out}} = \text{LN}_C^{\text{out}}(C + D_{(\text{MC} \rightarrow C)}). \quad (3.13)$$

Hai CP blocks MR/MC dùng ranks 8/8; bốn directed adapters, bốn dynamic gates và bốn learnable scales còn hoạt động. Output vẫn là 128/64/64, nên downstream read-




Hình 3.7: Residual routing của RC-Free Pairwise Fusion theo ba hàng modality đích. MRI nhận MR và MC, radiomics nhận MR, clinical nhận MC. Mỗi hàng giữ đường identity, cộng contribution rồi LayerNorm; $(RC \rightarrow R)$ và $(RC \rightarrow C)$ không hoạt động.

out và temporal model không đổi. Biến thể RC-Free Fixed- λ chỉ cố định bốn scales bằng 0.1 để khảo sát sensitivity, không thay thế kiến trúc chính. Loại một interaction không đồng nghĩa kết luận hai modality vô ích hoặc độc lập về mặt y học.


3.9 Tổng quan pipeline cuối

Hình 3.8 liên kết toàn bộ các bước. Tại mỗi visit, ba branches tạo M_t, R_t, C_t ; hai CP pair blocks tạo MR và MC; gated residual routing tạo $M_{out,t}, R_{out,t}, C_{out,t}$. Phép nối giữ thứ tự MRI–radiomics–clinical, sinh 256 chiều và readout xuống $F_t \in \mathbb{R}^{128}$. Chuỗi (F_1, F_2, F_3) cùng các khoảng cách ngày MRI đi vào T-LSTM, attention và Cox head.


1 XỬ LÝ TỪNG VISIT (cùng trọng số cho 3 visits)



2 CP PAIRWISE + DYNAMIC GATED RESIDUAL ROUTING



3 LONGITUDINAL SURVIVAL



Hình 3.8: Kiến trúc tổng thể của Longitudinal Learning with Tensor Fusion. Khối 3D biểu diễn MRI và xử lý không gian; các embedding sau pooling là vector. Ba encoders, CP MR/MC và residual routing tạo visit representation; T-LSTM và attention tổng hợp ba visits. Head xuất raw Cox log-risk, không qua sigmoid; huấn luyện dùng Cox partial likelihood với Breslow ties. Không có direct RC interaction.

Bảng 3.5: Shape từng bước của RC-Free (B : batch bệnh nhân, $T = 3$).

Bước / tensor	Shape hoặc phép biến đổi
MRI sequence	$[B, 3, 1, 144, 144, 144]$
CNN pooling / MRI projection	$[B, 3, 512] \rightarrow [B, 3, 128]$
Radiomics: đầu vào PCA / MLP	$[B, 3, 16] \rightarrow [B, 3, 128] \rightarrow [B, 3, 64]$
Clinical + masks / MLP	Hai $[B, 3, 9] \rightarrow [B, 3, 18] \rightarrow [B, 3, 64]$
Low projections $\tilde{M}, \tilde{R}, \tilde{C}$	$[B, 3, 32], [B, 3, 32], [B, 3, 16]$
CP MR/MC: $u, v, q = u \odot v$	Mỗi tensor $[B, 3, 8]$ ở từng pair
CP output / post-MLP	$[B, 3, 8] \rightarrow [B, 3, 128] \rightarrow [B, 3, 64]$
(MR $\rightarrow M$), (MC $\rightarrow M$)	Mỗi directed feature $[B, 3, 128]$
(MR $\rightarrow R$), (MC $\rightarrow C$)	Mỗi directed feature $[B, 3, 64]$
Gate / global route scale	Mỗi gate $[B, 3, 1]$; mỗi λ là scalar $[]$
$M_{\text{out}}, R_{\text{out}}, C_{\text{out}}$	$[B, 3, 128], [B, 3, 64], [B, 3, 64]$
Concatenate / shared readout	$[B, 3, 256] \rightarrow [B, 3, 128]$
Khoảng thời gian / visit mask	Mỗi tensor $[B, 3]$
T-LSTM: hidden / cell	Chuỗi $[B, 3, 128]$; hidden/cell $[B, 128]$
Attention / squeeze	$[B, 3, 128] \rightarrow [B, 3, 64] \rightarrow [B, 3, 1] \rightarrow [B, 3]$
Weighted context	$[B, 128]$
Cox head / raw log-risk	$[B, 128] \rightarrow [B, 64] \rightarrow [B, 1] \rightarrow [B]$

3.10 Mô hình thời gian và temporal attention

T-LSTM xử lý khoảng cách visit không đều qua sự suy giảm short-term memory [1, 15]. Khoảng thời gian đầu bằng không; các khoảng còn lại là $\Delta t_t = (s_t - s_{t-1})/365.25$, đo bằng năm. Không dùng số thứ tự visit thay cho khoảng ngày và không thêm learned time embedding.

Từ memory trước đó c_{t-1} , cell phân tách và điều chỉnh:


$$c_{t-1}^S = \tanh(W_S c_{t-1} + b_S), \quad c_{t-1}^L = c_{t-1} - c_{t-1}^S, \quad (3.14)$$

$$\gamma_t = \frac{1}{\log(e + \Delta t_t)}, \quad c_{t-1}^* = c_{t-1}^L + \gamma_t c_{t-1}^S. \quad (3.15)$$

Input, forget, output gates và candidate được tính từ F_t và h_{t-1} bằng các phép chiếu tuyến tính; cell cập nhật

$$c_t = f_t \odot c_{t-1}^* + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t). \quad (3.16)$$

Mô hình dùng một layer unidirectional, hidden 128. Thời gian tác động vào decay của



Hình 3.9: Ba visit embeddings và khoảng cách MRI đi qua T-LSTM: $\Delta t_1 = 0$, còn $\Delta t_2, \Delta t_3$ là khoảng cách giữa MRI liên tiếp tính bằng năm. Additive attention chấm điểm các hidden states rồi lấy tổng có trọng số làm subject representation cho Cox head. Visit mask điều khiển temporal aggregation, khác với masks cho từng giá trị clinical.

short-term memory; khi visit mask không hợp lệ, cell giữ trạng thái trước. Cohort hiện có đủ ba visits, nhưng cơ chế mask được giữ trong implementation.

Masked additive attention lấy cảm hứng từ cơ chế chấm điểm học được [16]:

$$e_t = v_a^\top \tanh(W_a h_t + b_a), \quad \alpha_t = \frac{\exp(e_t)}{\sum_{j \in \mathcal{V}} \exp(e_j)}, \quad z = \sum_{t \in \mathcal{V}} \alpha_t h_t. \quad (3.17)$$

$\mathcal{V}$ là tập visits hợp lệ. Attention projection dùng $128 \rightarrow 64 \rightarrow 1$, và $z \in \mathbb{R}^{128}$. Temporal weights phản ánh cách tổng hợp chuỗi của mạng, không phải mức quan trọng lâm sàng đã được xác nhận của từng visit.

3.11 Cox objective, huấn luyện và lựa chọn mô hình

Survival head dùng Linear $128 \rightarrow 64$, GELU, Dropout 0.30 và Linear $64 \rightarrow 1$ để sinh raw log-risk η_i . Không đặt sigmoid hoặc softmax cuối head. Với giả định proportional hazards [9],

$$h(\tau | z_i) = h_0(\tau) \exp(\eta_i). \quad (3.18)$$

Điểm nguy cơ lớn hơn tương ứng nguy cơ event sớm hơn; nó không trực tiếp là xác suất tiến triển ở một horizon cụ thể.

Gọi τ_k là các event times khác nhau, $\mathcal{D}_k$ là nhóm events tại τ_k , $d_k = |\mathcal{D}_k|$ và $\mathcal{R}_k = \{j : t_j \geq \tau_k\}$. Negative partial log-likelihood với Breslow ties [11], trung bình trên số events N_e , là

$$\mathcal{L}_{\text{Cox}} = -\frac{1}{N_e} \sum_k \left[\sum_{i \in \mathcal{D}_k} \eta_i - d_k \log \left(\sum_{j \in \mathcal{R}_k} \exp(\eta_j) \right) \right]. \quad (3.19)$$

Trong training thực tế, $\mathcal{R}_k$ chỉ gồm bệnh nhân trong *physical minibatch*, nên đây là xấp xỉ risk set toàn training cohort. Gradient accumulation không ghép các risk sets thành full-cohort likelihood. Validation loss được tính trên toàn bộ 54 người. Cox arithmetic dùng FP32 và log-sum-exp để giữ ổn định số học.

Protocol chính dùng AdamW [38] với learning rate 10^{-4} , weight decay 10^{-4} , betas (0.9, 0.999). Physical batch gồm 6 người, tích lũy gradient hai bước; sampling có xét event, không replacement hoặc oversampling. Mô hình dùng AMP FP16, clipping norm 1.0 và tối đa 100 epochs. ReduceLROnPlateau theo full-validation Cox loss dùng factor 0.5, patience 5 và learning rate tối thiểu 10^{-6} . Early stopping theo validation C-index có warm-up 10 epochs, patience 20 và min-delta 0.002. Best checkpoint được lưu theo validation C-index [12]; các run giữ checkpoint cuối để audit trajectory.

Ba seeds 20260727, 20260728 và 20260729 thay đổi khởi tạo, sampling và optimization trên cùng split cố định. Architecture selection sử dụng validation, kiểm tra nhiều seed và standardized validation benchmark; không dùng historical test metrics làm tiêu chí lựa chọn. Formal held-out final evaluation chưa được thực hiện trong phase đánh giá cuối. Kết luận về hiệu năng ở Chương 4 vì vậy là bằng chứng validation trong cohort và protocol đã mô tả.

Chương 4

Thực nghiệm, kết quả và phân tích

Chương này trình bày thực nghiệm theo thứ tự hình thành các quyết định nghiên cứu: đo tín hiệu từ dữ liệu bằng và MRI, bổ sung thông tin đa phương thức, xây dựng tương tác cặp, giảm kích thước lõi song tuyến bằng CP, rồi kiểm tra cấu trúc tương tác bằng ablation. Các kết quả là bằng chứng phát triển trên validation; chúng chưa thay thế một đánh giá khái quát hóa cuối cùng trên tập giữ lại độc lập.

4.1 Giao thức thực nghiệm

Cohort đóng băng gồm 359 người và 1.077 lượt khám, đúng ba visit cho mỗi người. Split theo người bệnh gồm 251 người train, 54 người validation và 54 người test; tương ứng có 74, 16 và 16 event. Mọi thí nghiệm sử dụng cùng phân chia RID. Chuẩn hóa clinical, radiomics và PCA chỉ được fit trên train; các artifact đã đóng băng được tái sử dụng cho validation. Đầu ra là raw risk, với giá trị lớn hơn biểu thị nguy cơ chuyển đổi sớm hơn.

Trong các bảng so sánh hiệu năng, **dòng in đậm** có C-index cao nhất trong cùng bảng; nếu báo cáo nhiều seed, tiêu chí là **mean C-index** và mọi dòng đồng hạng đều được in đậm. Bảng protocol, cấu hình và số tham số không dùng quy tắc này vì giá trị lớn hơn không đồng nghĩa với hiệu năng tốt hơn.

Các bảng phân biệt ba loại bằng chứng: kết quả lịch sử của một seed; ablation thay đổi một thành phần trong cùng họ mô hình; và benchmark validation chuẩn hóa trên ba seed 20260727, 20260728, 20260729. Không đặt một điểm single-seed cạnh trung bình ba seed như hai đại lượng tương đương. Benchmark đối chiếu split, preprocessing, kiến trúc và checkpoint, rồi replay các run đã tồn tại; nó không huấn luyện thêm mô hình.

Các deep model được chọn checkpoint theo validation C-index. Với họ Medical-Net Pairwise, CP Pairwise và RC-Free Pairwise, giao thức chung dùng AdamW, learning rate 10^{-4} , weight decay 10^{-4} , FP16 AMP, clipping norm 1, tối đa 100 epoch và ReduceLROnPlateau theo Cox loss toàn validation [38]. Early stopping theo C-index dùng warmup 10 epoch, patience 20 và min-delta 0,002. Cox loss dùng Breslow để xử lý event đồng thời [9, 11]. Risk set khi train là minibatch vật lý; gradient accumulation không biến nó thành risk set của toàn train cohort.

Bảng 4.1: Các giao thức phải phân biệt khi đọc tiến trình thực nghiệm.

Nhóm thí nghiệm	Cox batch	Số seed	Phạm vi diễn giải
MRI Only; Longitudinal MRI	6	1	Milestone lịch sử
Multimodal Concat.	8	1	Milestone lịch sử
Dynamic/MedicalNet Pairwise	6	1 hoặc 3	So sánh initialization có kiểm soát
CP/RC-Free Pairwise	6	3	So sánh trong họ pairwise
Fusion ablations	6	1	Một thay đổi so với full CP
Paper CNN-T-LSTM	16 (T-LSTM)	3	Adaptation, tối ưu riêng trên train

Chỉ số chuẩn hóa cho các deep model là Harrell-style C-index: một người có event được so sánh với người có thời gian theo dõi lớn hơn; risk bằng nhau nhận 0,5 điểm, còn thời gian sống còn bằng nhau không tạo cặp so sánh [12]. Validation gồm 54 người tạo 480 cặp hợp lệ theo quy ước này. P01 sử dụng `concordance_index_censored` của `scikit-survival` (đã đối chiếu mã nguồn phiên bản 0.28.0)¹, cho phép so sánh event với trường hợp censored tại cùng thời điểm; do đó kết quả classical được báo riêng [52]. Cùng một split không đồng nghĩa với cùng toàn bộ giao thức.

4.2 Baseline cổ điển và dữ liệu bảng

Trước khi học trực tiếp MRI, tám representation được xây dựng từ clinical kèm observedness mask, radiomics bin32/bin64 sau PCA, và tổ hợp của chúng. Clinical có 18 đầu vào mỗi visit; radiomics bin32 có 17 thành phần, bin64 có 16 thành phần. Cox

¹Mã nguồn metric theo phiên bản: <https://github.com/sebp/scikit-survival/blob/v0.28.0/sksurv/metrics.py>.

elastic-net sử dụng regularization kết hợp ℓ_1 và ℓ_2 [55]; RSF mở rộng ensemble cây cho dữ liệu kiểm duyệt phải [56]. Hyperparameter của Cox elastic-net được chọn bằng 5-fold cross-validation theo RID trên train, với 48 cấu hình trên tám representation. RSF gồm 300 cây được thử ở bốn representation đã chọn theo train CV, tổng cộng 32 cấu hình. Sau train CV, các ứng viên được đánh giá và lựa chọn theo validation.

Bảng 4.2: Validation của các representation dữ liệu bảng. Dòng in đậm đạt C-index cao nhất ở cả Cox và RSF. Dấu “–” nghĩa là RSF không được chạy cho representation đó.

Đầu vào	Số chiều	Cox	RSF
Clinical, visit cuối	18	0,837838	0,790021
Clinical, ba visit	54	0,837838	0,837838
Radiomics bin32, visit cuối	17	0,744283	–
Radiomics bin32, ba visit	51	0,582121	–
Radiomics bin64, visit cuối	16	0,748441	–
Radiomics bin64, ba visit	48	0,559252	–
Clinical + bin32, ba visit	105	0,852391	0,839917
Clinical + bin64, ba visit	102	0,860707	0,856549

Ứng viên được giữ là Cox trên clinical và radiomics bin64 của ba visit, với $\alpha = 0,1$ và $l1_ratio = 0,5$. Train-CV đạt $0,854910 \pm 0,056547$; đây là biến thiên giữa các fold, không phải SD giữa các seed. Validation đạt 0,860707, cao về mặt số học so với các kết quả neural ở phần sau, nhưng là giá trị sau lựa chọn representation và model family. Khóa luận không dùng nó để khẳng định ưu thế dưới một giao thức hoàn toàn đồng nhất. Kết quả vẫn cho thấy clinical có tín hiệu tiên lượng mạnh và mạng sâu cần được đối chiếu nghiêm túc với baseline cổ điển.

4.3 Baseline MRI một thời điểm

MRI Only sử dụng MRI tại visit cuối và 3D ResNet-18. Controlled comparison đầu tiên chỉ thay initialization của backbone. MedicalNet đạt 0,733333, trong khi random initialization đạt 0,787500 ở seed 20260727; vì vậy random ResNet được giữ làm comparator cho chuỗi longitudinal ban đầu. Kết quả này không hỗ trợ phát biểu rằng pretraining luôn có lợi. Các giá trị được đối chiếu với báo cáo controlled comparison.

Nhánh thích nghi CrossFormer3D từ hướng CrossFormer [28] giảm số tham số MRI Only từ 33.051.969 xuống 9.856.501 và đạt 0,764583. Đây là hướng khảo sát hiệu quả tính toán; trên cùng seed, nó không vượt random ResNet. Nhánh này được ghi

Bảng 4.3: Milestone MRI-only trên seed 20260727; dòng in đậm có C-index cao nhất. Dòng attention có provenance giới hạn và không thuộc benchmark ba seed.

Mô hình	Biểu diễn thời gian	Val C-index
MRI Only – MedicalNet	Visit cuối	0,733333
MRI Only – random ResNet	Visit cuối	0,787500
MRI Only – CrossFormer	Visit cuối	0,764583
Longitudinal MRI	T-LSTM, last hidden	0,733333
Longitudinal MRI + attention*	T-LSTM + attention	0,783333
Longitudinal MRI – CrossFormer	T-LSTM + attention	0,725000

nhận như một so sánh backbone, không phải bước thay thế bắt buộc trong kiến trúc cuối.

4.4 MRI dọc theo thời gian

Longitudinal MRI dùng shared ResNet cho ba visit, T-LSTM và Cox head. Phiên bản lấy last hidden đạt 0,733333. Run bổ sung attention ban đầu dùng do AMP overflow; run được sửa về số học ghi nhận best-observed 0,783333, nhưng thiếu closure đầy đủ. Giá trị attention được trình bày với dấu sao để tránh xếp hạng như một run hoàn tất có provenance mạnh.

So với random MRI Only 0,787500, các milestone hiện có chưa chứng minh cải thiện ổn định khi thêm temporal modeling. Điều này không bác bỏ giá trị của dữ liệu dọc: representation, khả năng tối ưu trên cohort nhỏ và cách tổng hợp chuỗi đều có thể ảnh hưởng kết quả. Cần so sánh nhiều seed dưới một giao thức matched trước khi quy kết lợi ích riêng cho T-LSTM hoặc attention.

4.5 Multimodal Concatenation

Multimodal Concatenation thêm radiomics và clinical vào chuỗi ba visit, ghép $M \parallel R \parallel C$, rồi giữ T-LSTM, attention và Cox head. Milestone đạt validation 0,812500, cao hơn các milestone longitudinal MRI-only. Kết quả phù hợp với giả thuyết thông tin đa phương thức có giá trị bổ sung, nhưng không cô lập hiệu ứng của từng modality: physical Cox batch tăng từ 6 lên 8 và comparator attention có provenance giới hạn.


4.6 Dynamic Pairwise Fusion

Để kiểm tra tương tác chéo rõ hơn concatenation, Dynamic Pairwise Fusion tạo MR, MC, RC bằng outer-product sau chiếu giảm chiều, rồi đưa interaction về các modality qua sáu route có gate, λ và identity residual. Random-ResNet variant đạt 0,828125. Chênh lệch +0,015625 so với concat là quan sát lịch sử, không phải ablation chỉ thay fusion, vì physical Cox batch giảm từ 8 xuống 6.


Controlled MedicalNet variant giữ kiến trúc và giao thức của Dynamic Pairwise, chỉ đổi initialization MRI; validation ở seed 20260727 đạt 0,839583. Như vậy MedicalNet có lợi trong bối cảnh pairwise này, khác với kết quả MRI Only. Variant có pretraining trở thành full outer-product reference cho thí nghiệm CP. Hình 4.1 tách các nhóm giao thức để thể hiện quá trình nghiên cứu mà không tạo một đường tăng điểm giả định giữa mọi giai đoạn.

Validation C-index


1 MRI Only: cùng protocol, khác initialization




2 Longitudinal MRI: Cox batch 6



3 Multimodal Concat.: Cox batch 8



4 Pairwise family: Cox batch 6



Hình 4.1: Các milestone validation theo tiến trình nghiên cứu ở seed 20260727, tách theo giao thức. Concatenation dùng Cox batch 8, các nhóm ResNet còn lại dùng batch 6; không nối các panel thành một xu hướng có kiểm soát. Dấu sao và marker rỗng chỉ kết quả attention best-observed có artifact hoàn tất còn hạn chế.

4.7 Paper CNN–T-LSTM Adaptation

Kiến trúc tham chiếu từ Aghajanian và cộng sự dùng CNN để trích embedding MRI dọc, PCA, T-LSTM và temporal attention cho dự báo sống còn [1]. Track của project được gọi là *adaptation*: cohort, tiền xử lý và cấu hình huấn luyện không trùng hoàn toàn với bài báo. Một cấu hình T-LSTM được chọn bằng retuning giới hạn trong train, rồi khóa cho cả ba seed; outer validation và test không được dùng trong bước

chọn hyperparameter đó.

CNN của mỗi seed được huấn luyện riêng, sau đó cố định để trích embedding 512 chiều tại global average pooling trước dropout. PCA99 fit riêng trên train tạo 38, 69 và 2 thành phần lần lượt ở seed 20260727, 20260728 và 20260729 (Bảng 3.3). T-LSTM dùng hidden size 64, Adam, batch 16 và learning rate khoảng $2,246 \times 10^{-4}$. Validation đạt $0,741667 \pm 0,069347$, thấp hơn các họ pairwise trên cohort hiện tại và biến thiên đáng kể theo seed. Đây là giới hạn chuyển giao của adaptation; nó không phải so sánh trực tiếp với điểm công bố của bài báo, cũng không cô lập riêng đóng góp của CP vì đầu vào và training scheme khác nhau.

4.8 CP-Factorized Pairwise Fusion

CP được thử sau khi full outer-product reference đã tồn tại. Controlled experiment chỉ thay phép biến đổi song tuyến đầu tiên: từ outer-product, flatten và full Linear sang $O(A^T x \odot B^T y) + b$. Encoder, post-MLP của từng pair, directed projection, gate, λ , residual, T-LSTM, attention và giao thức tối ưu được giữ nguyên. Ranks MR/MC/RC là 8/8/4. CP tham số hóa tensor trọng số song tuyến; không phân rã dữ liệu của bệnh nhân.

Trên ba seed chuẩn hóa, full outer-product đạt $0,834375 \pm 0,014768$, còn full CP đạt $0,827778 \pm 0,025007$. Chênh lệch trung bình CP trừ full là $-0,006597$. Vì vậy CP không chứng minh cải thiện C-index trong thí nghiệm này. Lợi ích đo được là giảm tham số interaction, với mức validation vẫn gần reference; đây là đánh đổi hiệu quả biểu diễn và hiệu năng, không phải kết luận tương đương thống kê.


4.9 Ablation của các thành phần fusion

Ablation dùng full CP làm reference và chỉ thay một thành phần tại seed 20260727. Các cấu hình còn lại, bao gồm split, pretraining và ranks, được giữ theo giao thức CP. Bảng 4.4 và Hình 4.2 trình bày cả tăng lẫn giảm điểm để tránh chỉ chọn các kết quả thuận lợi.

Bảng 4.4: Ablation validation ở seed 20260727; Δ được tính so với full CP. Dòng in đậm có C-index cao nhất.

Thay đổi	Val C-index	Δ
Full CP reference	0,821875	0
Bỏ dynamic gate	0,820833	-0,001042
Cố định $\lambda = 0,1$	0,836458	+0,014583
Bỏ identity residual	0,827083	+0,005208
Bỏ MR interaction	0,816667	-0,005208
Bỏ MC interaction	0,837500	+0,015625
Bỏ RC interaction	0,841667	+0,019792

Δ validation C-index so với Full CP Pairwise



Hình 4.2: Thay đổi validation C-index khi bỏ hoặc cố định từng thành phần so với full CP reference 0,821875 ở seed 20260727, cùng cohort và split. Đây là bằng chứng khám phá từ một seed, không có error bar hoặc diễn giải ý nghĩa thống kê.

Bỏ MR làm giảm điểm, còn bỏ RC tạo mức tăng mô tả lớn nhất. Tuy nhiên, bỏ identity residual và cố định λ cũng tăng ở seed này; ablation không xác nhận rằng mọi thành phần đề xuất đều cải thiện hiệu năng. Kết quả chỉ đặt ra giả thuyết rằng direct RC chưa cần thiết trong cohort hiện tại. Không suy từ nó rằng RC có hại nói chung

hoặc các route tương ứng biểu diễn quan hệ nhân quả.

4.10 RC-Free Pairwise Fusion qua nhiều seed

Giả thuyết rút gọn được kiểm tra bằng ba seed. RC-Free Pairwise Fusion vẫn giữ MRI, radiomics và clinical; chỉ bỏ direct RC và hai route ($RC \rightarrow R$), ($RC \rightarrow C$). MR, MC, bốn dynamic gate, bốn learnable λ , identity residual và mô hình thời gian được giữ lại.

Mean validation đạt 0,834722 với sample SD 0,023693: cao hơn full CP khoảng 0,006944 và gần full outer-product, với chênh lệch mean chỉ 0,000347. RC-Free không tốt hơn ở mọi seed; ở seed 20260729, điểm 0,808333 thấp hơn full outer-product 0,817708. Vì vậy lựa chọn này dựa trên cấu trúc interaction gọn hơn cùng validation cạnh tranh, không dựa trên tuyên bố vượt trội ổn định.

Follow-up RC-Free Fixed- λ cố định cả bốn hệ số ở 0,1, giữ gate và residual. Mean bằng đúng RC-Free, nhưng SD tăng từ 0,023693 lên 0,031273. Cấu hình này không đưa ra bằng chứng lợi ích rõ ràng; khóa luận giữ learnable λ trong kiến trúc được chọn. SD khác nhau với chỉ ba seed chưa đủ để chứng minh một variant ổn định hơn trong quần thể.

4.11 Benchmark validation chuẩn hóa


Benchmark chuẩn hóa đối chiếu các best checkpoint qua ba seed, kiểm tra fingerprint của split, preprocessing train-only và quy ước C-index. Cả 15 ô model–seed được tái sử dụng, không cần huấn luyện lại. P10 vẫn giữ pipeline đặc thù của adaptation; benchmark chuẩn hóa đánh giá, không biến các model family thành một ablation duy nhất.

Bảng 4.5: C-index validation chuẩn hóa: mean $\pm$ sample SD ($n = 3$). Hai dòng in đậm đồng hạng theo mean. Seed 27/28/29 là 20260727/20260728/20260729.

Mô hình	Seed 27	Seed 28	Seed 29	Mean $\pm$ SD
Paper CNN–T–LSTM	0,662500	0,770833	0,791667	0,741667 $\pm$ 0,069347
MedicalNet Pairwise	0,839583	0,845833	0,817708	0,834375 $\pm$ 0,014768
CP Pairwise	0,821875	0,855208	0,806250	0,827778 $\pm$ 0,025007
RC-Free Pairwise	0,841667	0,854167	0,808333	0,834722 $\pm$ 0,023693
RC-Free Fixed-λ	0,833333	0,866667	0,804167	0,834722 $\pm$ 0,031273

Trong bảng, Paper CNN-T-LSTM là CNN-PCA-T-LSTM Adaptation; MedicalNet Pairwise là full outer-product reference; CP Pairwise là full three-pair CP; RC-Free Pairwise là kiến trúc CP bỏ direct RC. Sample SD được tính với mẫu số $n - 1$. Ba seed là ba initialization trên cùng split, không phải ba cohort độc lập.

54 validation subjects | 480 comparable pairs



Hình 4.3: Benchmark validation trên ba seed: mean và sample SD của năm deep model. Error bar thể hiện dao động giữa seed trên cùng split; không phải khoảng tin cậy. Classical baseline được trình bày riêng do model selection và quy ước tied time khác.

Full MedicalNet Pairwise có SD thấp nhất trong nhóm pairwise. RC-Free và Fixed- λ cùng mean; chênh lệch RC-Free với full outer-product rất nhỏ. Do đó RC-Free là một lựa chọn đánh đổi hợp lý giữa cấu trúc đơn giản và validation cạnh tranh, không phải “mô hình tốt nhất tuyệt đối”. Validation được tái sử dụng trong nhiều quyết định kiến trúc, nên các điểm này có selection bias; benchmark không xóa giới hạn đó.

4.12 Hiệu quả về số tham số


Ba phép biến đổi song tuyến đầu tiên của full outer-product có 229.696 tham số gồm bias. CP giảm chúng còn 3.712, tương đương 98,384%. Các post-MLP không thay

đối; tính cả post-MLP, tổng của ba pair block giảm từ 248.608 còn 22.624. Bảng 4.6 phân biệt lỗi interaction với toàn bộ mạng để tránh diễn giải mức giảm 98% như giảm toàn mô hình.


Bảng 4.6: Số tham số phép biến đổi song tuyến đầu tiên, gồm bias. CP ranks MR/MC/RC là 8/8/4.

Phạm vi	Full outer-product	CP
MR: $32 \times 32 \rightarrow 128$	131.200	1.664
MC: $32 \times 16 \rightarrow 128$	65.664	1.536
RC: $32 \times 16 \rightarrow 64$	32.832	512
Tổng ba lớp đầu	229.696	3.712
Ba pair block, gồm post-MLP	248.608	22.624
Toàn mô hình	33.760.941	33.534.957

a Ba first bilinear layers (MR, MC, RC; gồm bias)



b Toàn bộ mô hình: backbone MRI chiếm phần lớn tham số



Hình 4.4: Giảm tham số từ full outer-product sang CP: 98,384% ở các lớp song tuyến đầu tiên, nhưng chỉ 0,669% ở toàn mô hình do MRI encoder chiếm phần lớn tham số. Post-MLP được giữ nguyên.

RC-Free có tổng 33.519.497 tham số, trong đó hai pair block MR/MC có 19.968

tham số, lõi CP có 3.200, bốn gate có 25.348 và bốn λ là bốn scalar học được. Fixed- λ còn 33.519.493 tham số. Việc bỏ RC chủ yếu đơn giản hóa interaction graph; mức giảm toàn mạng là nhỏ. Parameter count không thay thế phép đo FLOPs, latency hoặc memory. Các run có số epoch dừng khác nhau nên thời gian train tổng không được dùng như một benchmark tốc độ có kiểm soát.

4.13 Trả lời câu hỏi nghiên cứu và trạng thái test

Bảng 4.7: Kết luận cho các câu hỏi nghiên cứu, giới hạn ở evidence validation hiện có.

RQ	Kết luận và giới hạn
RQ1	Chưa thấy lợi ích ổn định của longitudinal MRI so với random MRI Only; attention repaired có provenance giới hạn. Cần đối chiếu matched qua nhiều seed.
RQ2	Concat có milestone cao hơn longitudinal MRI-only, phù hợp với thông tin bổ sung từ clinical/radiomics; khác Cox batch và provenance hạn chế cản trở quy toàn bộ gain cho modality.
RQ3	Pairwise có điểm lịch sử cao hơn concat, nhưng Cox batch 6/8 khác nhau. Đây là bằng chứng cho giả thuyết fusion, chưa phải kiểm định fusion-only đầy đủ.
RQ4	CP giảm 98,384% tham số ở first bilinear core; mean validation giảm 0,006597 so với full reference. Lợi ích chính là tham số hóa gọn.
RQ5	Bỏ RC tăng điểm ở ablation seed và giữ mean cạnh tranh qua ba seed; chưa chứng minh RC có hại nói chung. Fixed- λ không tăng mean so với RC-Free.

Architecture selection trong khóa luận dựa trên validation, ablation và benchmark nhiều seed. Formal Final Test Evaluation của project vẫn chưa được thực hiện trong nguồn evidence hiện có: *“Formal held-out final evaluation has not yet been performed.”* Các đánh giá test hậu nghiệm trong tài liệu lịch sử không được đưa vào bảng so sánh hoặc dùng để chọn interaction, rank hay kiến trúc. Vì test đã từng xuất hiện trong quá trình nghiên cứu trước đó, đánh giá tiếp theo trên split này cũng cần công bố lịch sử sử dụng test; external validation hoặc một tập giữ lại mới sẽ cung cấp bằng chứng khái quát hóa mạnh hơn.

Chương 5

Thảo luận, kết luận và hướng phát triển

Các thí nghiệm trong Chương 4 trả lời một câu hỏi thiết kế cụ thể: có thể khai thác thông tin đa phương thức bằng một interaction graph gọn hơn mà vẫn giữ hiệu năng validation cạnh tranh hay không? Chương này diễn giải các bằng chứng, phân biệt kết luận được hỗ trợ với giả thuyết cần kiểm chứng thêm, và xác định phạm vi sử dụng của mô hình.

5.1 Thảo luận

Kết quả cho thấy dùng ba MRI chưa mang lại lợi ích ổn định so với một MRI. Ghép thêm radiomics và dữ liệu lâm sàng tạo tín hiệu tích cực trên validation, nhưng các giai đoạn còn khác cấu hình huấn luyện nên chưa thể tách riêng lợi ích của từng thành phần. Việc thêm thời điểm hay nguồn thông tin cần được kiểm tra trong cùng điều kiện thí nghiệm.

CP phân rã tensor trọng số của lớp tương tác đầu tiên [35], giúp giảm mạnh số tham số của khối này. Trong ba seed, điểm validation trung bình giảm nhẹ so với full outer-product; kết quả chưa cho thấy CP tự cải thiện dự báo. Vì MRI encoder vẫn chiếm phần lớn tham số, mức giảm của toàn mạng nhỏ hơn nhiều. Lợi ích về tốc độ và bộ nhớ cần được đo trực tiếp.

RC-Free được chọn sau ablation một seed và kiểm tra lại bằng ba seed. Mô hình giữ đủ MRI, radiomics và dữ liệu lâm sàng, chỉ bỏ tương tác trực tiếp radiomics-clinical. MRI kết nối với hai nhánh còn lại qua MR và MC (Hình 5.1); gate điều chỉnh đóng góp theo đầu vào, còn residual giữ thông tin gốc. Kết quả ủng hộ một cấu trúc gọn có hiệu năng validation cạnh tranh trên bộ dữ liệu hiện tại, chưa chứng minh RC vô ích trên mọi dữ liệu. Gate và attention cũng chưa được kiểm chứng như chỉ dấu lâm sàng.



Hình 5.1: Topology cuối được lựa chọn qua validation và ablation: mô hình giữ đủ MRI, radiomics và clinical, sử dụng MRI làm trung tâm tương tác sau khi bỏ direct radiomics–clinical pair. Các cạnh biểu diễn trao đổi feature qua MR/MC, không phải quan hệ nhân quả hay kết nối giải phẫu.

Cox elastic-net là đối chứng mạnh cho dữ liệu bảng. Tuy nhiên, khác biệt về cách tính C-index và chọn mô hình khiến so sánh với mạng sâu chưa hoàn toàn đồng nhất. Vì vậy, các kết luận chỉ áp dụng trong điều kiện thí nghiệm hiện có.

5.2 Giới hạn

1. **Dữ liệu và thời điểm dự báo.** Mẫu nghiên cứu gồm 359 người ADNI có đủ ba MRI trong 18 tháng và không tiến triển sớm. Biến cố dựa trên ngưỡng MMSE/CDR, chưa thay thế chẩn đoán AD được xác nhận. Mốc dự báo là MRI thứ ba, nhưng điều kiện chọn mẫu được kiểm tra đến hết 18 tháng; dữ liệu lâm sàng ghép trong ± 90 ngày còn có thể xuất hiện sau MRI. Vì vậy, kết quả chưa chứng minh khả năng dự báo bằng dữ liệu có sẵn đúng tại thời điểm đó.
2. **Độ chắc chắn của kết quả.** Tập validation chỉ có 54 người và 16 biến cố. Ba seed dùng cùng một phép chia dữ liệu; độ lệch chuẩn giữa seed không phải khoảng tin cậy. Ablation ban đầu chỉ chạy một seed, còn nhiều lần chọn mô hình trên validation có thể làm hiệu năng được đánh giá quá cao. Một số đối chứng khác cấu hình huấn luyện; Cox loss tính trên từng nhóm mẫu (batch) và C-index chỉ đánh giá thứ hạng nguy cơ, chưa đánh giá độ chính xác của xác suất dự báo.
3. **Kiểm chứng trên dữ liệu mới và hiệu quả triển khai.** Các thí nghiệm trước từng dùng tập test; đánh giá cuối cùng theo quy trình chính thức vẫn chưa được thực hiện. Mô hình chưa được kiểm tra trên nhóm người độc lập, khi thiếu một nguồn dữ liệu hay khi chất lượng MRI thay đổi. Rank CP còn cố định, chưa so sánh nhiều giá trị trong cùng điều kiện huấn luyện. Mức giảm tham số cũng chưa chứng minh mức tiết kiệm thời gian hay bộ nhớ vì chưa có phép đo đồng nhất.

5.3 Kết luận

Khóa luận phát triển một pipeline survival từ MRI-only đến longitudinal MRI, ghép nối đa phương thức, dynamic pairwise fusion, CP-factorized interaction và ablation topology. Quá trình này xuất phát từ câu hỏi của nghiên cứu longitudinal MRI-radiomics: bổ sung một modality bằng ghép nối chưa bảo đảm khai thác được tín hiệu của nó [1].

Kiến trúc được chọn là RC-Free CP-Factorized Pairwise Fusion. Mô hình giữ MRI, radiomics và clinical, tham số hóa MR/MC bằng CP, đưa tương tác trở lại modality qua gated residual, rồi xử lý ba visit bằng T-LSTM và attention trước Cox head. Bằng chứng validation hiện tại ủng hộ một graph gọn có hiệu năng cạnh tranh; CP giảm chi phí của interaction core, còn loại RC đơn giản hóa topology. Các kết luận này là kết luận về thiết kế trong cohort hiện tại, chưa phải xác nhận ưu thế lâm sàng hoặc kết quả test.

5.4 Hướng phát triển

Ưu tiên đầu tiên là xây dựng và đánh giá protocol tiến cứu với time origin rõ ràng, eligibility phù hợp lúc dự báo và clinical chỉ lấy từ các ngày đã quan sát; xác nhận endpoint bằng chẩn đoán có thẩm định nếu có. Cần giữ provenance của dữ liệu hiện tại và tạo phiên bản cohort mới thay vì sửa âm thầm bản đóng băng.

Sau khi khóa protocol, nên thực hiện đối chứng MRI/temporal/modality trên cấu hình đồng nhất, mở rộng số split hoặc cohort độc lập, và chạy formal final evaluation có công bố lịch sử test. Calibration, time-dependent Brier score và các metric theo horizon sẽ bổ sung cho concordance [57]. Khoảng tin cậy theo người bệnh cần được tách khỏi SD theo seed.

Các hướng về kiến trúc gồm xử lý thiếu modality, rank-adaptive interaction, uncertainty-aware routing và temporal encoders mới khi quy mô dữ liệu cho phép. Pretrained brain representations như hướng brain latent diffusion có thể hữu ích [44], nhưng mọi cải tiến cần được kiểm tra bằng đối chứng phù hợp. Cuối cùng, đo latency, memory và độ ổn định trên phần cứng cố định sẽ làm rõ lợi ích triển khai thực sự của kiến trúc gọn.

TÀI LIỆU THAM KHẢO

- [1] Sepehr Aghajanian, Fateme Mohammadifard, Ida Mohammadi, Shahryar Rajai Firouzabadi, Ali Baradaran Bagheri, Elham Moases Ghaffary, and Omid Mirmosayyeb. Longitudinal structural MRI-based deep learning and radiomics features for predicting alzheimer’s disease progression. *Alzheimer’s Research & Therapy*, 17(1):182, 2025. DOI: [10.1186/s13195-025-01827-2](https://doi.org/10.1186/s13195-025-01827-2).
- [2] Ronald C. Petersen, Oscar Lopez, Melissa J. Armstrong, Thomas S. D. Getchius, Mary Ganguli, David Gloss, Gary S. Gronseth, Daniel Marson, Tamara Pringsheim, Gregory S. Day, Mark Sager, John Stevens, and Alexander Rae-Grant. Practice guideline update summary: Mild cognitive impairment: Report of the guideline development, dissemination, and implementation subcommittee of the american academy of neurology. *Neurology*, 90(3):126–135, 2018. DOI: [10.1212/WNL.0000000000004826](https://doi.org/10.1212/WNL.0000000000004826).
- [3] Clifford R. Jack, Jr., David A. Bennett, Kaj Blennow, Maria C. Carrillo, Billy Dunn, Samantha Budd Haeberlein, David M. Holtzman, William Jagust, Frank Jessen, Jason Karlawish, Enchi Liu, Jose Luis Molinuevo, Thomas Montine, Creighton Phelps, Katherine P. Rankin, Christopher C. Rowe, Philip Scheltens, Eric Siemers, Heather M. Snyder, and Reisa Sperling. NIA-AA research framework: Toward a biological definition of alzheimer’s disease. *Alzheimer’s & Dementia*, 14(4):535–562, 2018. DOI: [10.1016/j.jalz.2018.02.018](https://doi.org/10.1016/j.jalz.2018.02.018).
- [4] Joost J. M. van Griethuysen, Andriy Fedorov, Chintan Parmar, Ahmed Hosny, Nicole Aucoin, Vivek Narayan, Regina G. H. Beets-Tan, Jean-Christophe Fillion-Robin, Steve Pieper, and Hugo J. W. L. Aerts. Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21):e104–e107, 2017. DOI: [10.1158/0008-5472.CAN-17-0339](https://doi.org/10.1158/0008-5472.CAN-17-0339).
- [5] Michael W. Weiner, Dallas P. Veitch, Paul S. Aisen, Laurel A. Beckett, Nigel J. Cairns, Jesse Cedarbaum, Michael C. Donohue, Robert C. Green, Danielle Harvey,

- Clifford R. Jack, Jr., William Jagust, John C. Morris, Ronald C. Petersen, Andrew J. Saykin, Leslie M. Shaw, Paul M. Thompson, Arthur W. Toga, John Q. Trojanowski, and Alzheimer’s Disease Neuroimaging Initiative. Impact of the alzheimer’s disease neuroimaging initiative, 2004 to 2014. *Alzheimer’s & Dementia*, 11(7):865–884, 2015. DOI: [10.1016/j.jalz.2015.04.005](https://doi.org/10.1016/j.jalz.2015.04.005).
- [6] Amir Zadeh, Minghai Chen, Soujanya Poria, Erik Cambria, and Louis-Philippe Morency. Tensor fusion network for multimodal sentiment analysis. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 1103–1114. Association for Computational Linguistics, 2017. DOI: [10.18653/v1/D17-1115](https://doi.org/10.18653/v1/D17-1115).
- [7] Elena Ryumina, Maxim Markitantov, Alexandr Axyonov, Fedor Shchetinin, Timur Abdulkadirov, Dmitry Ryumin, and Alexey Karpov. Team RAS in 11th ABAW competition: Multimodal ambivalence recognition approach. *arXiv preprint arXiv:2607.14702*, 2026. DOI: [10.48550/arXiv.2607.14702](https://doi.org/10.48550/arXiv.2607.14702).
- [8] Jialin Liu, Xinwen He, Pengyu Liu, Jiale Shi, Huaijuan Zang, and Yanbin Hao. Motion reinforces appearance: RGB-skeleton gated residual fusion for micro-gesture online recognition. *arXiv preprint arXiv:2606.11645*, 2026. DOI: [10.48550/arXiv.2606.11645](https://doi.org/10.48550/arXiv.2606.11645).
- [9] David R. Cox. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B*, 34(2):187–202, 1972. DOI: [10.1111/j.2517-6161.1972.tb00899.x](https://doi.org/10.1111/j.2517-6161.1972.tb00899.x).
- [10] Jared L. Katzman, Uri Shaham, Alexander Cloninger, Jonathan Bates, Tingting Jiang, and Yuval Kluger. DeepSurv: Personalized treatment recommender system using a cox proportional hazards deep neural network. *BMC Medical Research Methodology*, 18:24, 2018. DOI: [10.1186/s12874-018-0482-1](https://doi.org/10.1186/s12874-018-0482-1).
- [11] Norman E. Breslow. Covariance analysis of censored survival data. *Biometrics*, 30(1):89–99, 1974. DOI: [10.2307/2529620](https://doi.org/10.2307/2529620).
- [12] Frank E. Harrell, Kerry L. Lee, and Daniel B. Mark. Multivariable prognostic models: Issues in developing models, evaluating assumptions and adequacy, and measuring and reducing errors. *Statistics in Medicine*, 15(4):361–387, 1996. DOI: [10.1002/\(SICI\)1097-0258\(19960229\)15:4<361::AID-SIM168>3.0.CO;2-4](https://doi.org/10.1002/(SICI)1097-0258(19960229)15:4<361::AID-SIM168>3.0.CO;2-4).
- [13] Hans C. van Houwelingen. Dynamic prediction by landmarking in event history

- analysis. *Scandinavian Journal of Statistics*, 34(1):70–85, 2007. DOI: [10.1111/j.1467-9469.2006.00529.x](https://doi.org/10.1111/j.1467-9469.2006.00529.x).
- [14] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
 - [15] Inci M. Baytas, Cao Xiao, Xi Zhang, Fei Wang, Anil K. Jain, and Jiayu Zhou. Patient subtyping via time-aware LSTM networks. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 65–74, 2017. DOI: [10.1145/3097983.3097997](https://doi.org/10.1145/3097983.3097997).
 - [16] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In *International Conference on Learning Representations*, 2015. <https://arxiv.org/abs/1409.0473>.
 - [17] Yann LeCun, Leon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. DOI: [10.1109/5.726791](https://doi.org/10.1109/5.726791).
 - [18] Du Tran, Lubomir Bourdev, Rob Fergus, Lorenzo Torresani, and Manohar Paluri. Learning spatiotemporal features with 3D convolutional networks. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 4489–4497, 2015. DOI: [10.1109/ICCV.2015.510](https://doi.org/10.1109/ICCV.2015.510).
 - [19] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016. DOI: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
 - [20] Sihong Chen, Kai Ma, and Yefeng Zheng. Med3D: Transfer learning for 3d medical image analysis. *arXiv preprint arXiv:1904.00625*, 2019. <https://arxiv.org/abs/1904.00625>.
 - [21] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 448–456, 2015. <https://proceedings.mlr.press/v37/ioffe15.html>.
 - [22] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016. <https://arxiv.org/abs/1607.06450>.

- [23] Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning*, pages 807–814, 2010. <https://icml.cc/2010/papers/432.pdf>.
- [24] Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016. <https://arxiv.org/abs/1606.08415>.
- [25] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.
- [26] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xi-aohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021. <https://arxiv.org/abs/2010.11929>.
- [27] Ali Hatamizadeh, Yucheng Tang, Vishwesh Nath, Dong Yang, Andriy Myronenko, Bennett Landman, Holger R. Roth, and Daguang Xu. UNETR: Transformers for 3D medical image segmentation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 574–584, 2022. https://openaccess.thecvf.com/content/WACV2022/html/Hatamizadeh_UNETR_Transformers_for_3D_Medical_Image_Segmentation_WACV_2022_paper.html.
- [28] Wenxiao Wang, Lu Yao, Long Chen, Binbin Lin, Deng Cai, Xiaofei He, and Wei Liu. CrossFormer: A versatile vision transformer hinging on cross-scale attention. In *International Conference on Learning Representations*, 2022. <https://arxiv.org/abs/2108.00154>.
- [29] Ian T. Jolliffe and Jorge Cadima. Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065): 20150202, 2016. DOI: [10.1098/rsta.2015.0202](https://doi.org/10.1098/rsta.2015.0202).
- [30] Marshal F. Folstein, Susan E. Folstein, and Paul R. McHugh. “Mini-mental state”: A practical method for grading the cognitive state of patients for the clinician. *Journal of Psychiatric Research*, 12(3):189–198, 1975. DOI: [10.1016/0022-3956\(75\)90026-6](https://doi.org/10.1016/0022-3956(75)90026-6).

- [31] John C. Morris. The clinical dementia rating (CDR): Current version and scoring rules. *Neurology*, 43(11):2412–2414, 1993. DOI: [10.1212/WNL.43.11.2412-a](https://doi.org/10.1212/WNL.43.11.2412-a).
- [32] Tadas Baltrušaitis, Chaitanya Ahuja, and Louis-Philippe Morency. Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2):423–443, 2019. DOI: [10.1109/TPAMI.2018.2798607](https://doi.org/10.1109/TPAMI.2018.2798607).
- [33] Zhun Liu, Ying Shen, Varun Bharadhwaj Lakshminarasimhan, Paul Pu Liang, AmirAli Bagher Zadeh, and Louis-Philippe Morency. Efficient low-rank multimodal fusion with modality-specific factors. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, pages 2247–2256, 2018. DOI: [10.18653/v1/P18-1209](https://doi.org/10.18653/v1/P18-1209).
- [34] J. Douglas Carroll and Jih-Jie Chang. Analysis of individual differences in multidimensional scaling via an n-way generalization of Eckart–Young decomposition. *Psychometrika*, 35(3):283–319, 1970. DOI: [10.1007/BF02310791](https://doi.org/10.1007/BF02310791).
- [35] Tamara G. Kolda and Brett W. Bader. Tensor decompositions and applications. *SIAM Review*, 51(3):455–500, 2009. DOI: [10.1137/07070111X](https://doi.org/10.1137/07070111X).
- [36] Hedi Ben-Younes, Remi Cadene, Matthieu Cord, and Nicolas Thome. MUTAN: Multimodal tucker fusion for visual question answering. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 2612–2620, 2017. DOI: [10.1109/ICCV.2017.285](https://doi.org/10.1109/ICCV.2017.285).
- [37] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15:1929–1958, 2014. <https://jmlr.org/papers/v15/srivastava14a.html>.
- [38] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. <https://arxiv.org/abs/1711.05101>.
- [39] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015. <https://arxiv.org/abs/1412.6980>.
- [40] Hongming Li, Yong Fan, and Alzheimer’s Disease Neuroimaging Initiative. Early prediction of alzheimer’s disease dementia based on baseline hippocampal mri and

- 1-year follow-up cognitive measures using deep recurrent neural networks. In *2019 IEEE 16th International Symposium on Biomedical Imaging (ISBI 2019)*, pages 368–371, 2019. DOI: [10.1109/ISBI.2019.8759397](https://doi.org/10.1109/ISBI.2019.8759397).
- [41] Huitong Ding, Biqu Wang, Alexander P. Hamel, Mark Melkonyan, Ting F. A. Ang, Alzheimer’s Disease Neuroimaging Initiative, Rhoda Au, and Honghuang Lin. Prediction of progression from mild cognitive impairment to alzheimer’s disease with longitudinal and multimodal data. *Frontiers in Dementia*, 2:1271680, 2023. DOI: [10.3389/frdem.2023.1271680](https://doi.org/10.3389/frdem.2023.1271680).
- [42] Rohan Bapat, Da Ma, and Tim Q. Duong. Predicting four-year’s alzheimer’s disease onset using longitudinal neurocognitive tests and mri data using explainable deep convolutional neural networks. *Journal of Alzheimer’s Disease*, 97(1):459–469, 2024. DOI: [10.3233/JAD-230893](https://doi.org/10.3233/JAD-230893).
- [43] Yu Zhang, Tong Liu, Vitaveska Lanfranchi, and Po Yang. Explainable tensor multi-task ensemble learning based on brain structure variation for alzheimer’s disease dynamic prediction. *IEEE Journal of Translational Engineering in Health and Medicine*, 11:1–12, 2023. DOI: [10.1109/JTEHM.2022.3219775](https://doi.org/10.1109/JTEHM.2022.3219775).
- [44] Zeqing Li, Linlin Gao, Liming Dong, and Hao Huang. Longitudinal multimodal modeling for alzheimer’s disease with pre-trained brain latent diffusion and mixture-of-experts fusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 4343–4350, 2026. https://openaccess.thecvf.com/content/CVPR2026W/DataMFM/html/Li_Longitudinal_Multimodal_Modeling_for_Alzheimers_Disease_with_Pre-trained_Brain_Latent_CVPRW_2026_paper.html.
- [45] Clifford R. Jack, Jr., Matt A. Bernstein, Nick C. Fox, Paul Thompson, Gene Alexander, Danielle Harvey, et al. The alzheimer’s disease neuroimaging initiative (ADNI): MRI methods. *Journal of Magnetic Resonance Imaging*, 27(4):685–691, 2008. DOI: [10.1002/jmri.21049](https://doi.org/10.1002/jmri.21049).
- [46] Andrew Hoopes, Jocelyn S. Mora, Adrian V. Dalca, Bruce Fischl, and Malte Hoffmann. SynthStrip: Skull-stripping for any brain image. *NeuroImage*, 260:119474, 2022. DOI: [10.1016/j.neuroimage.2022.119474](https://doi.org/10.1016/j.neuroimage.2022.119474).
- [47] M. Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, et al. MONAI: An open-source framework for deep learning in healthcare. *arXiv preprint arXiv:2211.02701*, 2022. <https://arxiv.org/abs/2211.02701>.

- [48] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019. https://proceedings.neurips.cc/paper_files/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html.
- [49] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke, and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [50] Wes McKinney. Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61, 2010. DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a).
- [51] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85):2825–2830, 2011. <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [52] Sebastian Pölsterl. Scikit-survival: A library for time-to-event analysis built on top of scikit-learn. *Journal of Machine Learning Research*, 21(212):1–6, 2020. <https://jmlr.org/papers/v21/20-729.html>.
- [53] John D. Hunter. Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [54] Mélodie Monod, Peter Krusche, Qian Cao, Berkman Sahiner, Nicholas Petrick, David Ohlssen, and Thibaud Coroller. TorchSurv: A lightweight package for deep survival analysis. *Journal of Open Source Software*, 9(104):7341, 2024. DOI: [10.21105/joss.07341](https://doi.org/10.21105/joss.07341).

- [55] Noah Simon, Jerome H. Friedman, Trevor Hastie, and Rob Tibshirani. Regularization paths for cox's proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13, 2011. DOI: [10.18637/jss.v039.i05](https://doi.org/10.18637/jss.v039.i05).
- [56] Hemant Ishwaran, Udaya B. Kogalur, Eugene H. Blackstone, and Michael S. Lauer. Random survival forests. *The Annals of Applied Statistics*, 2(3):841–860, 2008. DOI: [10.1214/08-A0AS169](https://doi.org/10.1214/08-A0AS169).
- [57] Erika Graf, Claudia Schmoor, Willi Sauerbrei, and Martin Schumacher. Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17-18):2529–2545, 1999. DOI: [10.1002/\(SICI\)1097-0258\(19990915/30\)18:17/18<2529::AID-SIM274>3.0.CO;2-5](https://doi.org/10.1002/(SICI)1097-0258(19990915/30)18:17/18<2529::AID-SIM274>3.0.CO;2-5).